

# ESCUELA SUPERIOR POLITÉCNICA DE CHIMBORAZO

Maestría en Estadística con mención en Ciencia de Datos e Inteligencia Artificial

## PROYECTO INTEGRADOR FINAL

Informe técnico

### **Pipeline híbrido SQL + NoSQL para la detección temprana del riesgo de reprobación en educación secundaria**

**Módulo:** Bases de Datos para Datos Estructurados, no Estructurados  
e Introducción a Big Data para Ciencia de Datos

**Código:** M1721

**Modalidad:** Trabajo grupal (Grupo 1)

**Valor:** 3,50 puntos

#### **Autores**

Alexis Rivera  
Lissette Adriano  
Shirley Adriano  
Cristian Solís

Riobamba, 26 de septiembre de 2026

## Resumen

Se implementó un pipeline reproducible que integra el registro académico real *Student Performance* (UCI; dos centros portugueses, curso 2005–2006) almacenado en PostgreSQL en tercera forma normal, con evidencia conductual simulada (interacciones LMS, tutorías y alertas con texto libre) almacenada en MongoDB con validación de esquema. Una regla de identidad en dos etapas corrigió las cifras del avance: los datos contienen 674 estudiantes, 1 044 matrículas y 3 132 calificaciones, no 662, 1.028 y 3.084. Se aplicaron 26 reglas de calidad trazables y se construyó un dataset analítico de 1 044 matrículas con diccionario y linaje. La variable objetivo se definió como reprobación final ( $G3 < 10$ ; prevalencia 22,0 %). En los datos reales, la reprobación se concentra en Matemáticas (32,9 %) y, en Portugués, en la escuela Mousinho da Silveira (30,1 % frente a 7,6 %). Las reprobaciones previas son el factor de antecedente más fuerte (OR 5,58). Un modelo de predicción temprana al cierre del primer período, sin usar  $G3$  y con partición agrupada por estudiante, alcanzó un AUC-ROC en prueba de 0,948 [0,918; 0,972] con regresión logística y un recall de 0,902. El análisis de sensibilidad mostró que las variables simuladas no añaden información ( $\Delta AUC = 0,000$ ), como exige su proceso generador. Un benchmark de 23 798 500 eventos en un nodo justifica no usar Spark. Se recomienda institucionalizar una alerta al cierre del primer período y validar el modelo con datos LMS reales.

**Palabras clave:** ingeniería de datos, PostgreSQL, MongoDB, ETL, calidad de datos, predicción temprana, fuga de información, reproducibilidad.

## Índice

|                                                                              |           |
|------------------------------------------------------------------------------|-----------|
| <b>Resumen</b>                                                               | <b>1</b>  |
| <b>1. Introducción</b>                                                       | <b>5</b>  |
| 1.1. Contexto y problema . . . . .                                           | 5         |
| 1.2. Preguntas de análisis y decisión que se apoya . . . . .                 | 5         |
| 1.3. Objetivos . . . . .                                                     | 5         |
| 1.4. Evolución respecto al avance y correspondencia con la rúbrica . . . . . | 6         |
| <b>2. Fuentes de datos</b>                                                   | <b>7</b>  |
| <b>3. Arquitectura de la solución</b>                                        | <b>8</b>  |
| <b>4. Almacenamiento e integración</b>                                       | <b>9</b>  |
| 4.1. Modelo relacional (PostgreSQL, 3FN) . . . . .                           | 9         |
| 4.2. Modelo documental (MongoDB) . . . . .                                   | 11        |
| 4.3. Regla de integración y unidad de análisis . . . . .                     | 12        |
| <b>5. Calidad, limpieza y transformación</b>                                 | <b>13</b> |
| 5.1. Diagnóstico inicial . . . . .                                           | 13        |
| 5.2. Regla de identidad: de 1.044 filas a 674 estudiantes . . . . .          | 13        |
| 5.3. Catálogo de reglas de calidad . . . . .                                 | 13        |
| 5.4. Variable objetivo y variables derivadas . . . . .                       | 14        |

|                                                                                       |           |
|---------------------------------------------------------------------------------------|-----------|
| 5.5. Reglas contra la fuga de información . . . . .                                   | 14        |
| 5.6. Proceso generador de los datos simulados . . . . .                               | 14        |
| <b>6. Proceso ETL</b>                                                                 | <b>16</b> |
| 6.1. Extract . . . . .                                                                | 16        |
| 6.2. Transform . . . . .                                                              | 16        |
| 6.3. Load . . . . .                                                                   | 17        |
| 6.4. Evidencias de ejecución . . . . .                                                | 17        |
| 6.5. Reproducibilidad . . . . .                                                       | 17        |
| <b>7. Escalabilidad</b>                                                               | <b>18</b> |
| <b>8. Resultados e interpretación</b>                                                 | <b>19</b> |
| 8.1. Descripción de la población . . . . .                                            | 19        |
| 8.2. P1: evolución de la nota y combinaciones centro–signatura . . . . .              | 20        |
| 8.3. P2: condiciones que distinguen el rendimiento sobre y bajo el promedio . . . . . | 21        |
| 8.4. Pregunta principal: combinación de factores y acompañamiento asociado . . . . .  | 23        |
| 8.5. Modelo de predicción temprana . . . . .                                          | 23        |
| 8.6. Sensibilidad: datos reales frente a datos simulados . . . . .                    | 27        |
| 8.7. Componente no estructurado: texto libre de las alertas . . . . .                 | 27        |
| 8.8. Utilidad y limitaciones de los resultados . . . . .                              | 28        |
| <b>9. Conclusiones y recomendaciones</b>                                              | <b>28</b> |
| 9.1. Conclusiones . . . . .                                                           | 28        |
| 9.2. Recomendaciones para la coordinación y la orientación . . . . .                  | 29        |
| 9.3. Mejoras y próximos pasos . . . . .                                               | 29        |
| <b>10.Evidencias técnicas</b>                                                         | <b>29</b> |
| <b>Referencias</b>                                                                    | <b>31</b> |
| <b>A. DDL completo (PostgreSQL)</b>                                                   | <b>31</b> |
| <b>B. Diccionario de datos del dataset analítico</b>                                  | <b>34</b> |
| <b>C. Linaje de las variables</b>                                                     | <b>35</b> |
| <b>D. Correspondencia con el dataset esperado del avance</b>                          | <b>37</b> |
| <b>E. Posibles falsos negativos de la regla de identidad</b>                          | <b>37</b> |
| <b>F. Salidas adicionales</b>                                                         | <b>37</b> |

## Índice de figuras

|    |                                                                                                                                                         |    |
|----|---------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1. | Arquitectura del pipeline, de la adquisición al consumo. Azul: dato real; naranja: dato simulado; verde: integración. . . . .                           | 8  |
| 2. | Modelo entidad-relación del esquema <i>academico</i> (3FN). . . . .                                                                                     | 9  |
| 3. | Tiempo y huella de datos frente al número de eventos (escala log-log). . . . .                                                                          | 18 |
| 4. | Nota media por período, asignatura y escuela (evaluados; IC 95 %). . . . .                                                                              | 20 |
| 5. | Tasa de reprobación final por asignatura y escuela (IC 95 % de Wilson). . . . .                                                                         | 21 |
| 6. | Tamaño de efecto ( $\delta$ de Cliff, IC 95 % <i>bootstrap</i> ) de las variables ordinales y numéricas en P2. . . . .                                  | 22 |
| 7. | Gradiente de reprobación según el número de factores reales (izquierda) y odds ratios ajustados con errores agrupados por estudiante (derecha). . . . . | 23 |
| 8. | Curvas ROC y precisión-recall en prueba, escenario A (corte P1). . . . .                                                                                | 24 |
| 9. | Calibración en prueba (izquierda) e importancia por permutación del mejor modelo no lineal en CV (derecha), escenario A. . . . .                        | 26 |

## Índice de tablas

|     |                                                                                                                                             |    |
|-----|---------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1.  | Correspondencia entre las secciones del informe y los criterios de la rúbrica. . . . .                                                      | 6  |
| 2.  | Diagnóstico del avance: debilidades detectadas, impacto y decisión adoptada. . . . .                                                        | 7  |
| 3.  | Inventario y caracterización de las fuentes de datos. . . . .                                                                               | 8  |
| 4.  | Justificación de componentes tecnológicos y alternativas descartadas. . . . .                                                               | 9  |
| 5.  | Controles de integridad posteriores a la carga (valor observado frente a esperado). . . . .                                                 | 10 |
| 6.  | Salida de A-01: nota por asignatura y período (evaluados). . . . .                                                                          | 11 |
| 7.  | Salida de A-02: reprobación final por escuela y asignatura. . . . .                                                                         | 11 |
| 8.  | Salidas de AG-04 <sup>SIM</sup> (alertas con tutoría posterior, izquierda) y AG-05 <sup>SIM</sup> (nivel $\times$ estado, derecha). . . . . | 12 |
| 9.  | Catálogo de reglas de calidad, transformación e integración con registros afectados (ejecución final). . . . .                              | 15 |
| 10. | Validación de las reglas: defectos inyectados por el generador frente a detectados por el ETL (datos simulados). . . . .                    | 16 |
| 11. | Conteos por etapa de la ejecución final (registros de entrada, rechazados y de salida). . . . .                                             | 17 |
| 12. | Duración por etapa. . . . .                                                                                                                 | 17 |
| 13. | Checksums de entradas y salidas principales. . . . .                                                                                        | 17 |
| 14. | Benchmark medido en un nodo (pandas + pyarrow): eventos LMS replicados. . . . .                                                             | 18 |
| 15. | Escenarios de escalado (supuestos explícitos; extrapolación del rendimiento medido). . . . .                                                | 19 |
| 16. | Descriptivos por asignatura (medianas y rango intercuartílico; notas de evaluados). . . . .                                                 | 19 |
| 17. | P1: cambio de la nota entre períodos (matrículas evaluadas en los tres períodos; Wilcoxon con Holm). . . . .                                | 20 |
| 18. | Reprobación por asignatura y escuela. . . . .                                                                                               | 21 |
| 19. | Reprobación en P3 según el estado en P1. . . . .                                                                                            | 21 |

|     |                                                                                                                                                                                                         |    |
|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 20. | P2: comparación sobre/bajo el promedio por asignatura (MW: Mann-Whitney U con $\delta$ de Cliff; $\chi^2$ : chi-cuadrado con diferencia de proporciones y V de Cramér; $p$ corregido por Holm). . . . . | 22 |
| 21. | Perfiles de riesgo: reprobación final y acompañamiento asociado (columnas [SIM] simuladas). . . . .                                                                                                     | 23 |
| 22. | Métricas de los modelos por escenario (CV: media $\pm$ DE en 5 pliegues agrupados; test: conjunto reservado, IC 95 % <i>bootstrap</i> por estudiante). . . . .                                          | 25 |
| 23. | Odds ratios del modelo logístico parsimonioso (corte P1; entrenamiento; errores agrupados por estudiante). . . . .                                                                                      | 26 |
| 24. | Desempeño del modelo A (logística) por estrato en prueba. . . . .                                                                                                                                       | 26 |
| 25. | Análisis de sensibilidad: cambio de AUC-ROC en prueba al añadir o quitar información (IC 95 % <i>bootstrap</i> pareado por estudiante). . . . .                                                         | 27 |
| 26. | AG-06 <sup>SIM</sup> : categoría inferida $\times$ nivel de alerta. . . . .                                                                                                                             | 28 |
| 27. | Ejemplos de normalización <sup>SIM</sup> . . . . .                                                                                                                                                      | 28 |
| 28. | Estructura del repositorio y artefactos entregados. . . . .                                                                                                                                             | 30 |
| 29. | Diccionario de datos del dataset analítico. . . . .                                                                                                                                                     | 34 |
| 30. | Linaje: de cada variable a su tabla/colección, campo y regla de transformación. . .                                                                                                                     | 35 |
| 31. | Variables del dataset esperado en el avance y su tratamiento final. . . . .                                                                                                                             | 37 |
| 32. | Pares sin emparejar que coinciden en 26 de 27 atributos (regla R-12b; no fusionados). .                                                                                                                 | 37 |
| 33. | Términos más frecuentes en las notas normalizadas <sup>SIM</sup> . . . . .                                                                                                                              | 38 |

## 1. Introducción

### 1.1 Contexto y problema

El rendimiento en educación secundaria depende de factores que las instituciones registran de forma fragmentada: calificaciones y reprobaciones previas en el sistema académico, asistencia en archivos planos, actividad digital en los registros de la plataforma virtual de aprendizaje (LMS) y acompañamiento en los registros manuales del departamento de orientación. Esta fragmentación impide identificar a tiempo a los estudiantes con riesgo de reprobación, cuando aún existe margen de intervención. El proyecto aborda ese problema desde la ingeniería de datos: integrar fuentes de estructura heterogénea en un almacenamiento híbrido y consolidarlas en un dataset analítico trazable que permita estimar el riesgo con la información disponible al cierre del primer período.

### 1.2 Preguntas de análisis y decisión que se apoya

La decisión que se apoya es **a quién derivar a tutoría al cierre del primer período**. Se mantienen las preguntas del avance:

- **P1.** ¿Cómo evoluciona la nota media de cada asignatura en los tres períodos y qué combinaciones de centro y asignatura concentran una tasa de reprobación que exija intervención?
- **P2.** ¿Qué condiciones (tiempo de estudio, faltas, reprobaciones previas, refuerzo, involucramiento en el LMS) distinguen a quienes rinden por encima del promedio de quienes quedan por debajo?
- **Pregunta principal.** ¿Qué estudiantes combinan bajo involucramiento en el LMS, alta inasistencia y reprobaciones previas, qué tutorías y alertas tienen asociadas y con qué exactitud puede predecirse tempranamente su riesgo de reprobación?

### 1.3 Objetivos

**Objetivo general.** Diseñar, implementar y documentar un pipeline de datos multimodal y reproducible que integre registros académicos estructurados con evidencia semiestructurada y no estructurada de acompañamiento, para construir un dataset analítico que permita estimar tempranamente el riesgo de reprobación y orientar intervenciones.

**Objetivos específicos.**

- OE1. Modelar el registro académico en PostgreSQL en 3FN con restricciones de integridad verificables.
- OE2. Modelar la evidencia conductual en MongoDB con validación de esquema e índices, cubriendo toda la población.
- OE3. Implementar un ETL con reglas de calidad numeradas, trazables y con conteo de registros afectados.
- OE4. Integrar ambas fuentes en un dataset analítico con unidad de análisis inequívoca, diccionario y linaje.
- OE5. Responder P1, P2 y la pregunta principal con pruebas estadísticas, tamaños de efecto e intervalos de confianza.
- OE6. Estimar un modelo de predicción temprana sin fuga de información y evaluar su sensibilidad a las variables simuladas.
- OE7. Justificar con mediciones la decisión sobre procesamiento distribuido.

**Beneficiarios.** Coordinación académica y departamento de orientación, que reciben un criterio de derivación temprana. También investigadores en analítica educativa, que reciben un pipeline reproducible y reutilizable.

#### 1.4 Evolución respecto al avance y correspondencia con la rúbrica

El informe es la evolución directa del avance: mismo problema, mismas fuentes, misma arquitectura base. Una revisión crítica del avance identificó dieciséis debilidades (Tabla 2). Todas se resolvieron y cada decisión se documenta en la sección indicada. La Tabla 1 relaciona cada sección con el criterio de la rúbrica que atiende.

**Tabla 1:** Correspondencia entre las secciones del informe y los criterios de la rúbrica.

| Criterio de la rúbrica           | Secciones y evidencias                                            | Peso |
|----------------------------------|-------------------------------------------------------------------|------|
| Arquitectura y diseño            | §1 (problema), §3 (arquitectura), §7 (escalabilidad)              | 20 % |
| Almacenamiento e integración     | §2 (fuentes), §4 (SQL, MongoDB, integración)                      | 20 % |
| ETL y calidad de datos           | §5 (reglas R-01...R-26, linaje), §6 (ETL, logs, reproducibilidad) | 25 % |
| Resultados e interpretación      | §8 (P1, P2, pregunta principal, modelo), §9 (conclusiones)        | 20 % |
| Documentación y reproducibilidad | §6.5, §10 (repositorio), anexos (DDL, diccionario, linaje)        | 15 % |

*Fuente:* elaboración propia a partir de la guía y rúbrica oficial.

**Tabla 2:** Diagnóstico del avance: debilidades detectadas, impacto y decisión adoptada.

| #  | Debilidad del avance                                      | Por qué afecta                   | Decisión en el informe final                                                                                         | §   |
|----|-----------------------------------------------------------|----------------------------------|----------------------------------------------------------------------------------------------------------------------|-----|
| 1  | <b>en_riesgo</b> sin definición operativa                 | Resultados no interpretables     | $G3 < 10$ (umbral oficial portugués); $G3 = 0$ cuenta como reprobación                                               | 5.4 |
| 2  | <b>promedio_general</b> incluía $G3$ (fuga)               | Predicción circular              | Escenarios de corte C, A (P1) y B (P2); $G3$ nunca es predictor (L-01)                                               | 5.5 |
| 3  | LMS y tutorías “correlacionados con el riesgo real”       | Hallazgos por construcción       | Generador explícito que no usa notas; prefijo <b>sim_</b> ; sensibilidad y contrafactual                             | 8.6 |
| 4  | 45 documentos para 662 estudiantes                        | Integración no representativa    | Cobertura del 100 %: 2022 documentos (674 estudiantes $\times$ 3 períodos)                                           | 4.2 |
| 5  | Unidad “estudiante-período” ambigua; etiqueta “2026-1”    | Trazabilidad                     | Fila = matrícula; $P1 \leftrightarrow G1$ , $P2 \leftrightarrow G2$ , $P3 \leftrightarrow G3$ con calendario 2005–06 | 4.3 |
| 6  | <b>actualizado_en</b> anterior a la tutoría               | Incoherencia temporal            | Validador <b>\$expr</b> + regla R-24 (34 corregidas)                                                                 | 4.2 |
| 7  | “382 estudiantes compartidos”                             | Conteo erróneo                   | 382 son filas de un <i>merge</i> con productos cruzados; los estudiantes compartidos son 370                         | 5.2 |
| 8  | 1.044 filas vs. 1.028 matrículas                          | Pérdida de datos reales          | Las 16 filas perdidas eran estudiantes distintos con igual clave: se recuperan (R-11)                                | 5.2 |
| 9  | $G3 = 0$ , <b>failures</b> truncado, 0 notas con 0 faltas | Sesgo en medias y asociaciones   | R-07, R-08, R-09 con conteos e impacto en N                                                                          | 5.3 |
| 10 | Texto libre mínimo                                        | Componente no estructurado débil | Normalización, conteo de términos, categorización e índice de texto                                                  | 8.7 |
| 11 | Escalabilidad sin cifras                                  | Arquitectura no justificada      | Benchmark medido hasta $\times 500$ y escenarios de proyección                                                       | 7   |
| 12 | <b>absences</b> es anual (no disponible en P1)            | Fuga temporal                    | Excluida del modelo temprano (L-02); solo sensibilidad                                                               | 5.5 |
| 13 | Mismo estudiante en entrenamiento y prueba                | Fuga por identidad               | Partición y validación cruzada agrupadas por estudiante (L-04)                                                       | 5.5 |
| 14 | 370 estudiantes con dos matrículas                        | Pseudorreplicación en pruebas    | Pruebas estratificadas por asignatura; errores agrupados por estudiante                                              | 8   |
| 15 | Nombres de tutores en el JSON de ejemplo                  | Privacidad                       | Códigos seudónimos ( <b>TUT-xx</b> , <b>ORI-xx</b> )                                                                 | 2   |
| 16 | Notas copiadas de SQL dentro de Mongo                     | Doble fuente de verdad           | SQL es la única fuente académica; Mongo solo guarda evidencia conductual                                             | 4.2 |

*Fuente:* elaboración propia; revisión del avance entregado por el Grupo 1.

## 2. Fuentes de datos

La Tabla 3 caracteriza las tres fuentes. Solo F1 es real. F2 y F3 son simuladas con un proceso generador explícito (§5.6), porque no se tuvo acceso a registros institucionales de LMS ni de orientación. Se declaran como **demonstración del pipeline**, no como evidencia sustantiva.

**Tabla 3:** Inventario y caracterización de las fuentes de datos.

|                        | F1 — Registro académico                                                    | F2 — Interacciones LMS <sup>SIM</sup>                                           | F3 — Tutorías y alertas <sup>SIM</sup>                                    |
|------------------------|----------------------------------------------------------------------------|---------------------------------------------------------------------------------|---------------------------------------------------------------------------|
| Origen                 | UCI ML Repository (Cortez, 2008), descarga automática y SHA-256 verificado | <code>generate_synthetic.py</code> , semilla 42                                 | <code>generate_synthetic.py</code> , semilla 42                           |
| Naturaleza             | Real (encuesta y registro escolar)                                         | Simulada                                                                        | Simulada                                                                  |
| Tipo y formato         | Estructurado; CSV con separador <code>;</code> , 33 columnas               | Semiestructurado; JSON Lines (log plano)                                        | Semiestructurado y texto libre; JSON                                      |
| Granularidad           | Estudiante $\times$ asignatura (fila); notas por período                   | Evento (clic/sesión)                                                            | Sesión de tutoría; alerta con historial y notas                           |
| Volumen                | 395 + 649 filas (150 kB)                                                   | 48 892 eventos crudos                                                           | 550 tutorías; 282 alertas; 575 notas                                      |
| Almacén                | PostgreSQL (esquema <code>academico</code> )                               | MongoDB ( <code>seguimiento_riesgo</code> )                                     | MongoDB ( <code>seguimiento_riesgo</code> , <code>alertas_riesgo</code> ) |
| Permisos               | CC BY 4.0; uso académico con cita                                          | Sin restricciones (sintético)                                                   | Sin restricciones (sintético)                                             |
| Riesgos de calidad     | Identidad sin ID; notas 0; <code>failures</code> truncado; faltas anuales  | Duplicados, tipos no estándar, duraciones inválidas, fechas fuera de calendario | Incoherencia temporal, categorías no estándar, texto con ruido            |
| Seguridad y privacidad | Datos anonimizados; ID seudónimo interno                                   | Sin datos personales                                                            | Tutores/orientadores con código; texto sin nombres                        |


Fuente: elaboración propia; documentación UCI (`student.txt`) y salidas de `extract.py` y `generate_synthetic.py`.

**Población de referencia.** Estudiantes de los centros Gabriel Pereira (GP) y Mousinho da Silveira (MS), Portugal, curso 2005–2006, en Matemáticas y Lengua Portuguesa. Las conclusiones sustantivas se refieren a esa población y no se extrapolan a otros sistemas educativos.

**Controles de seguridad adoptados.** (i) Credenciales fuera del código (`.env`, excluido del repositorio; `.env.example` sin secretos). (ii) Rol `analista_lectura` con privilegio mínimo (solo `SELECT`). (iii) Identificadores seudónimos. (iv) Separación de los datos simulados mediante el prefijo `sim_` y el campo `es_simulado`: `true`, exigido por el validador.

### 3. Arquitectura de la solución

La Figura 1 muestra el pipeline completo, desde la adquisición hasta el consumo. Un único orquestador (`run_pipeline.py`) ejecuta las etapas en orden y registra en `logs/` los conteos, las reglas aplicadas y los checksums de los artefactos.



**Figura 1:** Arquitectura del pipeline, de la adquisición al consumo. Azul: dato real; naranja: dato simulado; verde: integración.

Fuente: elaboración propia.

La Tabla 4 justifica cada componente y la alternativa descartada. El criterio rector es la *adecuación*

*al problema:* se usa cada tecnología solo donde su modelo de datos resuelve una necesidad concreta.

**Tabla 4:** Justificación de componentes tecnológicos y alternativas descartadas.


| Componente                                          | Justificación                                                                                                                                                                          | Alternativa descartada y motivo                                                                                                                                        |
|-----------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| PostgreSQL (16 en Docker; 18 en la ejecución local) | Datos académicos estables y relacionales; necesitan integridad referencial (PK/FK), dominios (CHECK), ACID y consultas con JOIN y agregación. La 3FN evita anomalías de actualización. | Guardar todo en MongoDB: se perderían las garantías de integridad y habría notas duplicadas por estudiante.                                                            |
| MongoDB 8                                           | Eventos y tutorías de cardinalidad variable (0 a cientos por estudiante), anidados y con esquema evolutivo; texto libre con índice de texto; pipelines \$unwind/\$group/\$lookup.      | Tabla de eventos en SQL: viable, pero rígida ante nuevos tipos de evento y sin modelar el documento “estudiante–período”, que es la unidad de consulta del orientador. |
| Parquet (+ CSV de respaldo)                         | Formato columnar tipado y comprimido para el consumo analítico; conserva tipos (bool, category, Int).                                                                                  | Solo CSV: pierde tipos y es mayor en disco.                                                                                                                            |
| Python (pandas, SQLAlchemy, PyMongo)                | Un solo lenguaje para ETL, estadística y ML; funciones con docstrings y pruebas <code>pytest</code> .                                                                                  | Herramientas ETL visuales: difíciles de versionar y reproducir.                                                                                                        |
| scikit-learn / statsmodels                          | Validación cruzada agrupada, pipelines sin fuga; inferencia (OR, IC) con errores agrupados.                                                                                            | Modelos opacos sin línea base ni calibración.                                                                                                                          |
| Spark (no usado)                                    | El volumen medido cabe en un nodo con holgura (\$7).                                                                                                                                   | Usarlo añadiría complejidad (JVM, clúster) sin beneficio medible.                                                                                                      |

*Fuente:* elaboración propia.

## 4. Almacenamiento e integración

### 4.1 Modelo relacional (PostgreSQL, 3FN)

El registro UCI mezcla atributos del estudiante, de la matrícula y tres notas en una fila. La normalización (Figura 2) sigue tres pasos. En 1FN, *G1*, *G2* y *G3* pasan a filas de **calificacion** con **periodo\_id**. En 2FN, los atributos que dependen de la asignatura (**failures**, **paid**, **absences**) van a **matricula**, cuya clave compuesta resuelve la relación N:M estudiante–asignatura, y los personales van a **estudiante**. En 3FN se extrae **escuela** para eliminar la dependencia transitiva estudiante → código de centro → nombre. La clasificación de atributos en personales o de matrícula se verificó empíricamente: en los 370 estudiantes emparejados, los 14 atributos personales coinciden en el 100 % de los casos (R-13, 0 conflictos), mientras que **failures** y **paid** difieren entre asignaturas. El marcador **reprobaciones\_3mas** se omitió en SQL porque es derivable de **reprobaciones\_previas** (violaría la 3FN) y se calcula en el dataset.



**Figura 2:** Modelo entidad–relación del esquema academico (3FN).

*Fuente:* `sql/01_ddl.sql`.

El Listado 1 muestra las dos tablas centrales. El DDL completo, con índices justificados, comentarios, la vista `v_matricula_ancha` y el rol de solo lectura, figura en el Anexo A.

**Listado 1:** Extracto del DDL: restricciones de matrícula y calificación.

```

CREATE TABLE matricula (
  estudiante_id    INTEGER NOT NULL REFERENCES estudiante (estudiante_id) ON DELETE CASCADE,
  asignatura_id    SMALLINT NOT NULL REFERENCES asignatura (asignatura_id),
  reprobaciones_previas SMALLINT NOT NULL CHECK (reprobaciones_previas BETWEEN 0 AND 3), -- 3 = "3 o mas"
  clases_pagadas   BOOLEAN NOT NULL,
  faltas           SMALLINT NOT NULL CHECK (faltas BETWEEN 0 AND 93),
  faltas_confiable BOOLEAN NOT NULL, -- anotacion de la regla R-09
  archivo_origen   VARCHAR(20) NOT NULL, fila_origen INTEGER NOT NULL, -- linaje
  PRIMARY KEY (estudiante_id, asignatura_id),
  UNIQUE (archivo_origen, fila_origen));
CREATE TABLE calificacion (
  estudiante_id INTEGER NOT NULL, asignatura_id SMALLINT NOT NULL,
  periodo_id   SMALLINT NOT NULL REFERENCES periodo (periodo_id),
  nota         SMALLINT NOT NULL CHECK (nota BETWEEN 0 AND 20), -- valor original UCI
  no_evaluado  BOOLEAN NOT NULL, -- anotacion de la regla R-08
  PRIMARY KEY (estudiante_id, asignatura_id, periodo_id),
  FOREIGN KEY (estudiante_id, asignatura_id) REFERENCES matricula ON DELETE CASCADE,
  CHECK (NOT no_evaluado OR nota = 0));
CREATE INDEX ix_calificacion_asig_per ON calificacion (asignatura_id, periodo_id);

```

**Evidencia de carga e integridad.** Se cargaron 4857 registros en PostgreSQL 18.6: 2 escuelas, 2 asignaturas, 3 períodos, 674 estudiantes, 1 044 matrículas y 3 132 calificaciones. Los 11 controles de `sql/03_integridad.sql` se superaron (Tabla 5). Además, una prueba automatizada verifica que el motor rechaza una nota fuera de dominio (CHECK). La ejecución que respalda este informe se hizo con PostgreSQL 18 y MongoDB 8.0 en instancias locales, porque el equipo no dispone de Docker. El `docker-compose.yml` declara PostgreSQL 16 y MongoDB 8.0. El DDL y las consultas solo usan funciones disponibles desde PostgreSQL 11 (FILTER, INCLUDE en índices, PERCENTILE\_CONT), pero la ejecución sobre el contenedor de la versión 16 no se verificó en este entorno.

**Tabla 5:** Controles de integridad posteriores a la carga (valor observado frente a esperado).

| Control                          | Valor | Esperado | OK |
|----------------------------------|-------|----------|----|
| I-01 estudiantes                 | 674   | 674      | ✓  |
| I-02 matriculas                  | 1 044 | 1 044    | ✓  |
| I-03 calificaciones              | 3 132 | 3 132    | ✓  |
| I-04 matriculas_sin_3_notas      | 0     | 0        | ✓  |
| I-05 estudiantes_sin_matricula   | 0     | 0        | ✓  |
| I-06 matriculas_huerfanas        | 0     | 0        | ✓  |
| I-07 estudiantes_en_ambas        | 370   | 370      | ✓  |
| I-08 notas_fuera_dominio         | 0     | 0        | ✓  |
| I-09 calificaciones_no_evaluadas | 74    | 74       | ✓  |
| I-10 filas_origen_duplicadas     | 0     | 0        | ✓  |
| I-11 filas_vista_integracion     | 1 044 | 1 044    | ✓  |

Fuente: `sql/03_integridad.sql`; salida en `results/sql_integridad.csv`.

**Consultas analíticas.** La consulta A-01 (JOIN de calificacion, asignatura y periodo con agregación filtrada) responde la parte descriptiva de P1 (Tabla 6). A-02 cruza cinco tablas para obtener la reprobación por escuela y asignatura (Tabla 7). El plan de ejecución (`results/sql_explain_A01.txt`) muestra que, con 3 132 filas, el optimizador prefiere recorridos secuenciales y *hash joins*. Los índices compuestos se justifican por el crecimiento esperado, no por el volumen actual.

**Tabla 6:** Salida de A-01: nota por asignatura y período (evaluados).

| Asignatura  | Período | n eval. | Media | DE   | Mediana | No eval. |
|-------------|---------|---------|-------|------|---------|----------|
| Matemáticas | P1      | 395     | 10,91 | 3,32 | 11      | 0        |
| Matemáticas | P2      | 382     | 11,08 | 3,25 | 11      | 13       |
| Matemáticas | P3      | 357     | 11,52 | 3,23 | 11      | 38       |
| Portugués   | P1      | 648     | 11,42 | 2,71 | 11      | 1        |
| Portugués   | P2      | 642     | 11,70 | 2,67 | 11      | 7        |
| Portugués   | P3      | 634     | 12,19 | 2,69 | 12      | 15       |

Fuente: `sql/04_analiticas.sql`; salida en `results/sql_A-01.csv`.

**Tabla 7:** Salida de A-02: reprobación final por escuela y asignatura.

| Escuela              | Asignatura  | Matríc. | Reprob. | Tasa   | No eval. |
|----------------------|-------------|---------|---------|--------|----------|
| Mousinho da Silveira | Matemáticas | 46      | 17      | 37,0 % | 4        |
| Gabriel Pereira      | Matemáticas | 349     | 113     | 32,4 % | 34       |
| Mousinho da Silveira | Portugués   | 226     | 68      | 30,1 % | 14       |
| Gabriel Pereira      | Portugués   | 423     | 32      | 7,6 %  | 1        |

Fuente: `sql/04_analiticas.sql`; salida en `results/sql_A-02.csv`.

## 4.2 Modelo documental (MongoDB)

Se mantienen las dos colecciones del avance, con tres correcciones: cobertura total, unidad explícita y SQL como única fuente de lo académico (Mongo no replica notas).

- **seguimiento\_riesgo: un documento por estudiante y período** ( $2022 = 674 \times 3$ ). Embebe `interacciones_lms[]` (47 597 eventos, cada uno con su `asignatura`) y `tutorias[]` (544). Incluye `periodo_inicio` y `periodo_fin` para validar la coherencia temporal. Tamaño: 5,6 MB.
- **alertas\_riesgo:** una alerta por matrícula y período (282), con ciclo de vida `historial_estados[]` (abierto  $\rightarrow$  en\_seguimiento  $\rightarrow$  cerrada) y `notas[]` de texto libre con su versión normalizada y su categoría.
- **cuarentena:** 342 registros rechazados por las reglas de calidad, con su motivo (trazabilidad).

**Validación de esquema.** Ambas colecciones se crean con `validationLevel: strict` y `validationAction: error`. El validador combina `$jsonSchema` (tipos, enumeraciones, patrones de identificadores, `es_simulado: true` obligatorio) con reglas `$expr` de coherencia temporal que el avance no controlaba (Listado 2). El pipeline prueba el validador en cada ejecución: inserta una alerta con `actualizado_en` anterior a su creación y un evento fuera de su período, y en ambos casos verifica que MongoDB los rechaza (`WriteError`).

**Listado 2:** Reglas `$expr` del validador de `alertas_riesgo` (extracto de `mongo/validadores.json`).

```
{ "$expr": { "$and": [
  { "$gte": [ "$actualizado_en", "$creada_en" ] },
  { "$gte": [ "$actualizado_en", { "$max": "$historial_estados.fecha" } ] },
  { "$gte": [ "$actualizado_en", { "$ifNull": [ { "$max": "$notas.fecha" }, "$creada_en" ] } ] },
  { "$gte": [ { "$ifNull": [ { "$min": "$notas.fecha" }, "$creada_en" ] }, "$creada_en" ] },
  { "$eq": [ "$estado", { "$arrayElemAt": [ "$historial_estados.estado", -1 ] } ] },
  { "$eq": [ { "$arrayElemAt": [ "$historial_estados.estado", 0 ] }, "abierta" ] } ] }
```

**Índices.** Se definieron siete índices, documentados en `mongo/indices.json`: (`estudiante_id`, `periodo`) único, que es la clave natural y evita duplicados; `periodo`, para el corte temporal; un índice multiclave (`interacciones_lms.asignatura`, `periodo`); `alerta_id` único; (`estado`,

nivel), para el tablero de orientación; y un índice de texto en español sobre `notas.texto_normalizado`.

**Pipelines de agregación.** Hay siete pipelines documentados, con sus salidas en `results/mongo_*.csv`. AG-01 aplana eventos (`$unwind`) y agrega actividad por estudiante, asignatura y período (`$group`, `$addToSet`, `$size`). AG-02 y AG-03 resumen tutorías y alertas por matrícula. AG-04 usa `$lookup` con subpipeline para verificar si cada alerta tuvo una tutoría posterior de la misma asignatura (Listado 3, Tabla 8). AG-05 y AG-06 describen el ciclo de vida y las categorías del texto. AG-07 ejecuta una búsqueda de texto completo que recupera 108 alertas con notas sobre inasistencias.

**Listado 3:** Pipeline AG-04 con `$lookup` correlacionado (extracto de `mongo/pipelines.json`).

```
[{"$lookup": {"from": "seguimiento_riesgo",
  "let": {"e": "$estudiante_id", "a": "$asignatura", "f": "$creada_en"},
  "pipeline": [{"$match": {"$expr": {"$eq": ["$estudiante_id", "$$e"]}},
    {"$unwind": "$tutorias"},
    {"$match": {"$expr": {"$and": [{"$eq": ["$tutorias.asignatura", "$$a"]},
      {"$gte": ["$tutorias.fecha", "$$f"]}}}}},
    {"$count": "n"}], "as": "tut"}},
{"$project": {"nivel": 1, "estado": 1, "n_tut": {"$ifNull": [{"$arrayElemAt": ["$tut.n", 0]}, 0]}},
{"$group": {"_id": "$nivel", "n_alertas": {"$sum": 1},
  "con_tutoria_posterior": {"$sum": {"$cond": [{"$gt": ["$n_tut", 0]}, 1, 0]}}}]
```

**Tabla 8:** Salidas de AG-04<sup>SIM</sup> (alertas con tutoría posterior, izquierda) y AG-05<sup>SIM</sup> (nivel × estado, derecha).

| Nivel | Alertas | Con tutoría posterior | %      | Cerradas |
|-------|---------|-----------------------|--------|----------|
| alto  | 108     | 77                    | 71,3 % | 60       |
| bajo  | 16      | 0                     | 0,0 %  | 13       |
| medio | 158     | 105                   | 66,5 % | 104      |

| Nivel | Abierta | En seguimiento | Cerrada |
|-------|---------|----------------|---------|
| alto  | 17      | 31             | 60      |
| medio | 26      | 28             | 104     |
| bajo  | 2       | 1              | 13      |

*Fuente:* `mongo/pipelines.json`; salidas en `results/mongo_AG-04.csv` y `results/mongo_AG-05.csv`. Datos simulados.

### 4.3 Regla de integración y unidad de análisis

**Unidad de análisis.** Una fila del dataset es una **matrícula** (estudiante × asignatura) observada con la información disponible en cada corte temporal. El mapeo de períodos es explícito: P1 ↔ G1 (15/09–16/12/2005), P2 ↔ G2 (03/01–24/03/2006) y P3 ↔ G3, la nota final (10/04–16/06/2006). Se descartó la unidad “estudiante–período” del avance por tres razones: la reprobación se decide por asignatura; **failures** y **absences** son atributos de la matrícula; y los tres períodos de una misma matrícula son medidas repetidas, no observaciones independientes. El dataset tiene 1 044 filas y 58 columnas.

**Regla de integración.** Se hace un LEFT JOIN desde la vista `v_matricula_ancha` (PostgreSQL) hacia las salidas de AG-01, AG-02 y AG-03 (MongoDB) por la clave (`estudiante_id`, `asignatura`). Se verifica que el número de filas no cambia (1:1). La ausencia de registros simulados se imputa como 0 actividad (R-26). El diccionario de datos (Anexo B) y la tabla de linaje (Anexo C) documentan tipo, dominio, origen y transformación de cada variable. El Anexo D relaciona las variables esperadas en el avance con las finales.

## 5. Calidad, limpieza y transformación

### 5.1 Diagnóstico inicial

El registro UCI no tiene valores faltantes (R-02), ni duplicados exactos (R-03), ni valores fuera de los dominios documentados (R-04, R-05). Sus problemas son de *semántica*, no de sintaxis: (i) no incluye identificador de estudiante; (ii) una nota 0 no es una nota real; (iii) **failures** está truncado; (iv) las faltas son un total anual. Las fuentes simuladas llevan defectos inyectados deliberadamente, con tasas explícitas, para ejercitar las reglas y verificar que cada una detecta exactamente lo que se inyectó (§5.6).

### 5.2 Regla de identidad: de 1.044 filas a 674 estudiantes

UCI indica que 382 estudiantes pertenecen a ambos archivos y que se identifican por 13 atributos comunes (*school, sex, age, address, famsize, Pstatus, Medu, Fedu, Mjob, Fjob, reason, nursery, internet*). La verificación reveló que la clave de 13 atributos **no es única dentro de cada archivo**: hay 15 grupos de filas con igual clave pero notas distintas, es decir, estudiantes distintos. Por eso el *merge* directo del script R de UCI produce 382 filas por productos cruzados, aunque solo existen 366 claves comunes. El avance deduplicó por clave: 391 claves en MAT + 637 en POR = 1028 “matrículas” y 662 “estudiantes” (unión de claves). Eso fusionó erróneamente a 16 estudiantes reales y explica las 16 matrículas perdidas.

La regla aplicada (`transform.py::resolver_identidad`) tiene dos etapas:

1. **Candidatos por clave exacta** de 13 atributos entre un archivo y el otro (nunca dentro del mismo archivo, R-11).
2. **Desambiguación** dentro de cada clave mediante una asignación 1:1 (algoritmo húngaro) que maximiza las coincidencias en 14 atributos personales que no dependen de la asignatura. Un par se acepta si alcanza al menos 12 de 14 coincidencias y el máximo es único.

Resultado: 370 pares aceptados. De ellos, 358 proceden de claves únicas (etapa 1) y 12 de claves ambiguas (etapa 2), y todos coinciden en 14 de 14 atributos. Las alternativas descartadas coincidían como máximo en 10 de 14. Por tanto, 1.044 filas – 370 pares = **674 estudiantes**: 370 en ambas asignaturas, 25 solo en Matemáticas y 279 solo en Portugués. Esto da **1 044 matrículas** y **3 132 calificaciones** ( $1044 \times 3$ ), cifras que corrigen las del avance.

**Riesgos de la regla.** Un *falso positivo* sería fusionar dos personas distintas; se mitiga exigiendo 12 o más coincidencias personales y un máximo único, y no se observó ningún conflicto. Un *falso negativo* sería no unir a la misma persona. El diagnóstico R-12b encontró 5 pares sin emparejar que coinciden en 26 de 27 atributos (Tabla 32, Anexo E): cuatro difieren solo en la edad, en filas consecutivas de ambos archivos, lo que sugiere un error de registro, y uno en la educación del padre. Se mantuvo la regla estricta y el número de estudiantes queda acotado entre 669 y 674 (0,7 %). El efecto sobre los resultados es despreciable, porque la unidad de análisis es la matrícula, que no cambia.

### 5.3 Catálogo de reglas de calidad

La Tabla 9 lista las reglas aplicadas con su justificación, implementación (archivo y función) y número de registros afectados en la ejecución final. Las decisiones sobre anomalías conocidas y su impacto en N son estas:

- **R-08, nota 0.** Hay 74 calificaciones con valor 0: 53 en G3, 20 en G2 y 1 en G1. En G3, todas tienen 0 faltas y la mayoría va precedida de notas positivas: es el patrón de abandono o de

no presentarse. Se conservan en SQL con `no_evaluado = true`, se excluyen de las medias (la inclusión ingenua sesgaría la media de Matemáticas en P3 de 11,52 a 10,42) y cuentan como reprobación en `en_riesgo`, porque desde la perspectiva institucional no aprobar es el evento de interés. El único  $G1 = 0$  va seguido de  $G2 = G3 = 11$ , lo que indica un registro faltante en P1.

- **R-07, failures.** La documentación indica “n si  $1 \leq n < 3$ ; si no, 4”, pero los datos solo contienen valores 0–3. Se interpreta 3 como “3 o más” (30 matrículas) y se trata como variable ordinal.
- **R-09, 0 faltas en no evaluados.** Las 53 matrículas con  $G3 = 0$  tienen 0 faltas, un valor implausible para un abandono. Se marcan con `faltas_confiable = false` y se excluyen de los análisis que dependen de las faltas (§8.4), con análisis de sensibilidad.
- **R-10, atípicos en faltas.** Hay 8 matrículas por encima de la valla extrema de Tukey. Se conservan, por tratarse de valores plausibles (máximo 75), y se usan métodos robustos (medianas, pruebas de rangos).

## 5.4 Variable objetivo y variables derivadas

**Definición operativa.** `en_riesgo = 1`  $\iff G3 < 10$ , que es el umbral de aprobación del sistema portugués en escala 0–20 (Cortez & Silva, 2008), e incluye los no evaluados ( $G3 = 0$ ). Afecta a 230 de 1 044 matrículas (22,0 % [19,6; 24,6]). Se eligió la reprobación *final* porque es el resultado que la institución quiere prevenir; la predicción *temprana* se logra restringiendo los predictores, no redefiniendo el objetivo. Otras variables derivadas son `rendimiento_sobre_promedio`, que vale 1 si  $G3$  supera la media de su asignatura y se usa en P2; `reprobaciones_3mas`; `faltas_atipicas`; `en_ambas_asignaturas`; y once variables simuladas `sim_*`.

## 5.5 Reglas contra la fuga de información

- **L-01.**  $G3$  solo define el objetivo; nunca es predictor. El `promedio_general` del avance, que incluía  $G3$ , se eliminó.
- **L-02.** `faltas` es un total anual y no está disponible al cierre de P1. Se excluye del modelo temprano y solo se usa como sensibilidad.
- **L-03.** Del LMS solo se usan eventos con fecha menor o igual al fin de P1. Las tutorías y alertas (P2–P3) son posteriores al corte y solo son descriptivas.
- **L-04.** La partición entrenamiento/prueba (80/20; 832/212) es estratificada, está *agrupada por estudiante* y se fijó en `integrate.py` antes de cualquier análisis. La validación cruzada también está agrupada.

Las pruebas automatizadas verifican L-01 a L-04 en cada ejecución (`tests/test_pipeline.py`).

## 5.6 Proceso generador de los datos simulados

El generador (`src/generate_synthetic.py`; semilla 42) cubre las 1 044 matrículas. Su diseño evita la circularidad señalada en el avance: **la actividad LMS no depende de ninguna nota.**

$$\begin{aligned}\eta_m &= -0,40 + 0,30(\text{estudio} - 2) - 0,35\text{reprob} + 0,40\text{internet} + 0,25\text{superior} + a_i + \varepsilon_m, \\ a_i &\sim N(0; 0,5^2), \quad \varepsilon_m \sim N(0; 0,5^2), \\ N_{mt} &\sim \text{Poisson}(12 e^{\eta_m} f_t), \quad f = (1; 0,9; 0,8) \text{ para P1, P2, P3,} \\ \text{duración} &\sim \text{LogNormal}(\ln 15 + 0,2\eta_m; 0,6), \text{ acotada a } [1, 240] \text{ min.}\end{aligned}$$

| ID     | Fuente             | Regla y diagnóstico                                                                                                                                                                             | Acción                                                                           | Afect. | Implementación                                        |
|--------|--------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------|--------|-------------------------------------------------------|
| R-01   | F1 UCI             | Esquema: 33 columnas esperadas y tipos declarados                                                                                                                                               | Validar/abortar                                                                  | 0      | extract.py::leer_csv                                  |
| R-02   | F1 UCI             | Valores faltantes en las 33 columnas                                                                                                                                                            | Diagnosticar (imputar si >0)                                                     | 0      | transform.py::diagnostico                             |
| R-03   | F1 UCI             | Filas duplicadas exactas (33 columnas) dentro de cada archivo                                                                                                                                   | Eliminar duplicados                                                              | 0      | transform.py::diagnostico                             |
| R-04   | F1 UCI             | Valores categóricos fuera del catálogo UCI                                                                                                                                                      | Validar/abortar                                                                  | 0      | transform.py::diagnostico                             |
| R-05   | F1 UCI             | Valores numéricos fuera de rango documentado                                                                                                                                                    | Validar/abortar                                                                  | 0      | transform.py::diagnostico                             |
| R-06   | F1 UCI             | Estandarización: 8 binarias yes/no -> booleano; códigos -> etiquetas en español; nombres snake_case                                                                                             | Transformar                                                                      | 1044   | transform.py::normalizar                              |
| R-07   | F1 UCI             | Reprobaciones previas truncadas: valor 3 codifica '3 o más'                                                                                                                                     | Conservar como ordinal 0-3 (3 = 3+); derivar reprobaciones_3mas en el dataset    | 30     | transform.py::normalizar                              |
| R-08   | F1 UCI             | Nota 0 interpretada como 'no evaluado' (G1=1, G2=20, G3=53)                                                                                                                                     | Marcar no_evaluado; excluir de medias; G3=0 cuenta como reprobación en en_riesgo | 74     | transform.py::normalizar                              |
| R-09   | F1 UCI             | Faltas = 0 en matrículas con G3 no evaluado (53 con G3=0, 53 con 0 faltas): registro de asistencia no confiable                                                                                 | Marcar faltas_confiable = false                                                  | 53     | transform.py::normalizar                              |
| R-10   | F1 UCI             | Faltas extremas (> Q3 + 3-RIC por asignatura)                                                                                                                                                   | Conservar (valores plausibles) y marcar; log1p en modelos                        | 8      | transform.py::normalizar                              |
| R-11   | F1 UCI             | Clave de 13 atributos repetida dentro del mismo archivo (15 grupos); fusionarlas eliminaría 16 matrículas reales                                                                                | No fusionar: cada fila es una matrícula distinta                                 | 31     | transform.py::resolver_identidad                      |
| R-12   | F1 UCI             | Emparejamiento MAT-POR: 366 claves comunes; merge ingenuo = 382 filas; pares aceptados = 370 (etapa 1: 358, etapa 2: 12); rechazados = 0                                                        | Asignar el mismo estudiante_id al par                                            | 370    | transform.py::resolver_identidad                      |
| R-12b  | F1 UCI             | Posibles falsos negativos: filas sin pareja que coinciden en 26/27 atributos con una fila sin pareja del otro archivo                                                                           | No fusionar (regla estricta); declarar y acotar el N de estudiantes              | 5      | transform.py::resolver_identidad                      |
| R-13   | F1 UCI             | Conflictos en atributos personales entre filas del mismo estudiante                                                                                                                             | Prevalece POR (archivo más completo) y se registra                               | 0      | transform.py::resolver_identidad                      |
| R-14   | F1 UCI             | Despivotado 1FN: G1, G2, G3 -> filas (matrícula × período)                                                                                                                                      | Transformar                                                                      | 3132   | transform.py::normalizar                              |
| R-15   | F2 LMS (sim.)      | Campos obligatorios ausentes (evento_id, estudiante_id, asignatura, fecha, tipo)                                                                                                                | Cuarentena                                                                       | 96     | transform_synthetic.py::limpiar_eventos               |
| R-16   | F2 LMS (sim.)      | Eventos duplicados (mismo evento_id)                                                                                                                                                            | Eliminar, conservar la primera aparición                                         | 959    | transform_synthetic.py::limpiar_eventos               |
| R-17   | F2 LMS (sim.)      | Integridad referencial: (estudiante_id, asignatura) sin matrícula en PostgreSQL                                                                                                                 | Cuarentena                                                                       | 96     | transform_synthetic.py::limpiar_eventos               |
| R-18   | F2 LMS (sim.)      | Fecha fuera del calendario lectivo 2005-2006                                                                                                                                                    | Cuarentena                                                                       | 144    | transform_synthetic.py::limpiar_eventos               |
| R-19   | F2 LMS (sim.)      | Asignación de período (P1/P2/P3) por fecha del evento                                                                                                                                           | Derivar campo periodo                                                            | 47597  | transform_synthetic.py::periodo_de                    |
| R-20   | F2 LMS (sim.)      | Tipo de evento no estandarizado (mayúsculas, espacios, inglés)                                                                                                                                  | Mapear al catálogo {recurso, tarea, foro, cuestionario}                          | 2397   | transform_synthetic.py::limpiar_eventos               |
| R-21   | F2 LMS (sim.)      | Duración negativa (error de registro)                                                                                                                                                           | Anular duración (el evento cuenta, no suma minutos)                              | 240    | transform_synthetic.py::limpiar_eventos               |
| R-22   | F2 LMS (sim.)      | Duración > 240 min (sesión no cerrada)                                                                                                                                                          | Truncar a 240 min                                                                | 240    | transform_synthetic.py::limpiar_eventos               |
| R-23   | F3 Tutorías (sim.) | Tutorías: resultado no estandarizado (28 mapeados) y fecha fuera de calendario o sin matrícula (6 a cuarentena)                                                                                 | Mapear resultado; cuarentena                                                     | 34     | transform_synthetic.py::limpiar_tutorias              |
| R-24   | F3 Alertas (sim.)  | Coherencia temporal: actualizado_en ≥ última fecha del historial/notas (corregidas 34); historial ordenado (0); estado = último del historial (0)                                               | Corregir y registrar                                                             | 34     | transform_synthetic.py::limpiar_alertas               |
| R-25   | F3 Alertas (sim.)  | Texto libre: normalización (minúsculas, tildes, abreviaturas, puntuación) y categorización por léxico ({'academico': 215, 'asistencia': 117, 'conducta': 73, 'familiar': 78, 'motivacion': 92}) | Derivar texto_normalizado y categoria                                            | 575    | transform_synthetic.py::normalizar_texto /categorizar |
| R-26   | Integración        | Matrículas sin registros simulados tras el LEFT JOIN (sin LMS en P1: 14; sin tutorías: 799; sin alertas: 762)                                                                                   | Imputar 0 (ausencia de registro = ausencia de actividad)                         | 1575   | integrate.py::construir                               |
| DEF-01 | Integración        | Variable objetivo en_riesgo = 1 si G3 < 10 (prevalencia 0.220)                                                                                                                                  | Derivar                                                                          | 230    | integrate.py::construir                               |
| L-04   | Integración        | Partición train/test (80/20) agrupada por estudiante y estratificada por en_riesgo; test = 212 matrículas                                                                                       | Fijar antes de explorar                                                          | 212    | integrate.py::construir                               |

Por construcción, la actividad LMS es condicionalmente independiente de  $G3$  dadas las covariables reales. Cualquier asociación que muestre el análisis se explica por esas covariables, y la sensibilidad del §8.6 lo confirma. Las tutorías (probabilidad 0,70 si  $G1 < 10$ ; 0,15 si hay reprobaciones previas; 0,04 en otro caso) y las alertas (alto si  $G1 < 8$ ; medio si  $8 \leq G1 < 10$  o si hay 2 o más reprobaciones) simulan una regla institucional de alerta temprana que se activa al cierre de P1 con información ya disponible. El texto libre se genera con plantillas por categoría y ruido tipográfico (tildes omitidas, mayúsculas, abreviaturas, espacios dobles).

Los defectos se inyectaron con tasas explícitas: 2 % de duplicados, 5 % de tipos no estándar, 0,5 % de duraciones negativas y 0,5 % de duraciones excesivas, 0,3 % de fechas fuera de calendario, 0,2 % de estudiantes inexistentes, 0,2 % de fechas faltantes y 12 % de alertas incoherentes. La Tabla 10 compara los defectos inyectados con los detectados: todas las reglas detectan exactamente lo inyectado, lo que valida su implementación.

**Tabla 10:** Validación de las reglas: defectos inyectados por el generador frente a detectados por el ETL (datos simulados).

| Defecto inyectado                  | Regla | Inyectados | Detectados | Coincide |
|------------------------------------|-------|------------|------------|----------|
| Campo obligatorio (fecha) ausente  | R-15  | 96         | 96         | ✓        |
| Evento duplicado                   | R-16  | 959        | 959        | ✓        |
| Estudiante inexistente             | R-17  | 96         | 96         | ✓        |
| Fecha fuera de calendario          | R-18  | 144        | 144        | ✓        |
| Tipo no estandarizado              | R-20  | 2 397      | 2 397      | ✓        |
| Duración negativa                  | R-21  | 240        | 240        | ✓        |
| Duración > 240 min                 | R-22  | 240        | 240        | ✓        |
| Tutoría: resultado/fecha           | R-23  | 34         | 34         | ✓        |
| Alerta: actualizado_en incoherente | R-24  | 34         | 34         | ✓        |

*Fuente:* `data/raw/synthetic/_verdad_generador.json` y `logs/reglas_calidad.csv`; verificado por `test_reglas_detectan_exactamente_lo_inyectado`.

## 6. Proceso ETL

### 6.1 Extract

`extract.py` descarga el ZIP oficial de UCI si falta y extrae el ZIP anidado. Verifica el SHA-256 de cada CSV contra el valor registrado en `config.py`, lee con esquema explícito de 33 columnas (R-01; los enteros llegan a veces entrecomillados) y añade las columnas de linaje `archivo_origen` y `fila_origen`. Deja una copia inmutable en `data/staging/uci_raw.parquet`. `generate_synthetic.py` escribe los JSON crudos simulados en `data/raw/synthetic/`, con el mismo formato que tendría una exportación de logs.

### 6.2 Transform

`transform.py` aplica R-02 a R-14 al registro UCI: diagnóstico, identidad, estandarización, anomalías y 1FN/3FN. Produce las seis tablas en `data/staging/`. `transform_synthetic.py` aplica R-15 a R-25 a los JSON: los registros inválidos pasan a cuarentena, los duplicados se eliminan, las categorías se mapean, se asigna el período por fecha y se corrige la coherencia temporal y el texto. Después construye los documentos de las colecciones. `integrate.py` aplica R-26 y L-04 y deriva la variable objetivo.

### 6.3 Load

`load.py` recrea el esquema (`01_ddl.sql`) e inserta las tablas en orden de dependencias dentro de una transacción. Luego crea la vista y el rol (02) y ejecuta los controles (03) y las consultas analíticas (04): si un control falla, la ejecución se detiene. En MongoDB crea las colecciones con validador e índices, inserta los documentos, registra en cuarentena los rechazos, prueba el validador y ejecuta los siete pipelines.

### 6.4 Evidencias de ejecución

La Tabla 11 resume los conteos de entrada, rechazo y salida por etapa de la ejecución final; la Tabla 12, la duración de cada etapa; y la Tabla 13, los checksums que permiten verificar la integridad de entradas y salidas. La duración total es de 84,5 s, la mayor parte en el análisis estadístico (*bootstrap*) y el benchmark.

**Tabla 11:** Conteos por etapa de la ejecución final (registros de entrada, rechazados y de salida).

| Etapas       | Operación                           | Entrada          | Rechazados | Salida               |
|--------------|-------------------------------------|------------------|------------|----------------------|
| Extract      | CSV UCI leídos (MAT + POR)          | 395 + 649        | 0          | 1 044                |
| Transform F1 | Resolución de identidad             | 1 044 filas      | 0          | 674 estudiantes      |
| Transform F1 | Normalización 3FN                   | 1 044 matrículas | 0          | 3 132 calificaciones |
| Generate     | Eventos LMS simulados + duplicados  | 48 892           | —          | —                    |
| Transform F2 | Limpieza de eventos (R-15...R-22)   | 48 892           | 1 295      | 47 597               |
| Transform F3 | Limpieza de tutorías (R-23)         | 550              | 6          | 544                  |
| Transform F3 | Alertas (R-24, R-25)                | 282              | 0          | 282                  |
| Load SQL     | Seis tablas en PostgreSQL           | 4 857            | 0          | 4 857                |
| Load NoSQL   | seguimiento_riesgo + alertas_riesgo | 2 304            | 0          | 2 304                |
| Integrate    | Dataset analítico (matrículas)      | 1 044            | 0          | 1 044                |

Fuente: `logs/ultima_ejecucion.json`.

**Tabla 12:** Duración por etapa.

| Etapas                | Duración (s) |
|-----------------------|--------------|
| 1_extract             | 0,07         |
| 2_transform_uci       | 0,27         |
| 3_generate_synthetic  | 0,67         |
| 4_transform_synthetic | 1,32         |
| 5_load_postgres       | 0,80         |
| 6_load_mongo          | 0,51         |
| 7_integrate           | 0,20         |
| 8_analysis            | 67,87        |
| 9_benchmark           | 8,04         |
| 10_notebook           | 4,76         |

**Tabla 13:** Checksums de entradas y salidas principales.

| Artefacto                                             | Filas | SHA-256 (prefijo)   |
|-------------------------------------------------------|-------|---------------------|
| <code>data/staging/uci_raw.parquet</code>             | 1 044 | 23f22921d8eef22a... |
| <code>data/processed/dataset_analitico.parquet</code> | 1 044 | 106adab68260eb3c... |
| <code>data/processed/dataset_analitico.csv</code>     | 1 044 | e7617c69757cd248... |
| <code>data/processed/diccionario_datos.csv</code>     | 58    | e4859b554b4965e4... |
| <code>data/raw/student-mat.csv</code>                 | 395   | e47f9ee225e1ee6e... |
| <code>data/raw/student-por.csv</code>                 | 649   | a7594a11d7771c0e... |

Fuente: `logs/ultima_ejecucion.json`; los hashes completos figuran en el mismo archivo.

### 6.5 Reproducibilidad

- **Un solo comando:** `python run_pipeline.py` reconstruye todo desde los CSV de UCI (o `make all`, que añade pruebas y PDF).
- **Semilla fija:** `SEED = 42` en la generación sintética, la partición, la validación cruzada, los modelos y cada *bootstrap*. Cada procedimiento aleatorio usa su propio generador sembrado, de modo que los resultados no dependen del orden de ejecución.

- **Determinismo verificado:** tres ejecuciones consecutivas produjeron archivos de resultados con SHA-256 idénticos. Las métricas se redondean a 6 decimales para absorber el ruido de coma flotante de los cálculos multihilo.
- **Entorno fijado:** `requirements.txt` (versiones exactas), `requirements-lock.txt` (pip freeze completo), `docker-compose.yml` (PostgreSQL 16 y MongoDB 8) y `.env.example`.
- **Pruebas:** 17 pruebas `pytest`, todas superadas: conteos, dominios, identidad, ausencia de fuga, detección igual a inyección, integridad en vivo, rechazo del validador y reproducibilidad del generador.
- **Cifras del informe generadas:** `report_tables.py` produce todas las tablas y macros numéricas de este documento a partir de `results/` y `logs/`; ninguna cifra se transcribió a mano.


## 7. Escalabilidad

**Pregunta.** ¿Requiere el caso procesamiento distribuido? Se respondió *midiendo*. `benchmark_escalabilidad.py` replica los eventos LMS limpios hasta  $\times 500$ , con estudiantes nuevos para que también crezca el número de grupos, y mide en un solo nodo (arm64 · 8 núcleos · 8 GB RAM · Darwin) la huella en memoria, el tamaño en Parquet y el tiempo de la agregación equivalente a AG-01 (Tabla 14, Figura 3).

**Tabla 14:** Benchmark medido en un nodo (pandas + pyarrow): eventos LMS replicados.

| Escala       | Eventos    | Grupos    | Memoria (MB) | Parquet (MB) | Agregación (s) | Escritura (s) | Lectura (s) |
|--------------|------------|-----------|--------------|--------------|----------------|---------------|-------------|
| $\times 1$   | 47 597     | 3 086     | 0,9          | 0,5          | 0,008          | 0,015         | 0,002       |
| $\times 10$  | 475 970    | 30 860    | 9,0          | 1,9          | 0,031          | 0,027         | 0,005       |
| $\times 100$ | 4 759 700  | 308 600   | 90,4         | 17,6         | 0,393          | 0,231         | 0,070       |
| $\times 250$ | 11 899 250 | 771 500   | 226,1        | 43,9         | 1,208          | 0,614         | 0,187       |
| $\times 500$ | 23 798 500 | 1 543 000 | 452,2        | 87,4         | 2,674          | 1,219         | 0,303       |

Fuente: `results/escalabilidad.csv`. Tiempos de una ejecución; varían levemente entre corridas.



**Figura 3:** Tiempo y huella de datos frente al número de eventos (escala log-log).

Fuente: `src/benchmark_escalabilidad.py`.

### Análisis de las cuatro V.

- **Volumen.** El caso real ocupa 150 kB en CSV y 47 597 eventos simulados. Incluso con 23 798 500 eventos, la huella es de 452 MB (19,0 bytes por fila) y la agregación tarda 2,67 s. En MongoDB, AG-01 sobre los datos reales tarda 0,062 s.

- **Velocidad.** Las notas se actualizan tres veces al año y la decisión (derivar a tutoría) es por lotes, al cierre de cada período. No hay un requisito de latencia que justifique *streaming*.
- **Variedad.** La heterogeneidad (tabular, documental, texto) se resuelve con el almacenamiento híbrido, no con cómputo distribuido.
- **Costo.** Spark exige JVM, configuración de clúster y serialización, lo que añade complejidad operativa y puntos de fallo sin mejorar ningún tiempo relevante del caso.

**Umbral de decisión.** Con 19,0 bytes por fila y un margen  $\times 3$  para intermedios, un nodo de 8 GB procesa unos 140 millones de eventos en memoria. La Tabla 15 proyecta escenarios con la tasa del generador (45,6 eventos por matrícula y año) y el rendimiento medido (8,9 millones de filas/s). Estas proyecciones son extrapolaciones lineales bajo supuestos declarados.

**Tabla 15:** Escenarios de escalado (supuestos explícitos; extrapolación del rendimiento medido).

| Escenario (supuesto)                                      | Eventos/año   | Memoria (GB) | Agregación estimada (s) | Un nodo 8 GB |
|-----------------------------------------------------------|---------------|--------------|-------------------------|--------------|
| Caso actual (UCI)                                         | 47 597        | 0,00         | 0,0                     | Sí           |
| Red de 100 centros (100 000 est. $\times$ 10 asignaturas) | 45 590 996    | 0,87         | 5,1                     | Sí           |
| Red nacional (1 000 000 est. $\times$ 10 asignaturas)     | 455 909 961   | 8,66         | 51,2                    | No           |
| Red nacional con clickstream ( $\times 20$ eventos)       | 9 118 199 233 | 173,25       | 1 024,3                 | No           |

Fuente: results/escalabilidad\_escenarios.csv.

**Decisión. No se implementa Spark.** El volumen real está 3,5 órdenes de magnitud por debajo del umbral de un nodo, y el benchmark lo confirma. Spark estaría justificado en el escenario de una red nacional con registros de clics (*clickstream*): unos  $10^9$ – $10^{10}$  eventos al año, que superan la memoria de un nodo, con ingesta continua (Spark Structured Streaming o Kafka), particionado por centro y fecha en Parquet y agregaciones distribuidas equivalentes a AG-01. La arquitectura actual ya facilita esa migración: Parquet columnar, agregaciones expresadas como *groupby* y un orquestador por etapas. Forzar Spark en este caso no aportaría el “valor real” que exige la bonificación.

## 8. Resultados e interpretación

**Convenciones.** Las secciones 8.1 a 8.4 usan solo datos reales, salvo las columnas marcadas [SIM]. Los intervalos son al 95 %: Wilson para proporciones, *t* para medias y *bootstrap* percentil (2.000 réplicas) para tamaños de efecto. Las comparaciones múltiples se corrigen por Holm. Como 370 estudiantes aportan dos matrículas, las pruebas se estratifican por asignatura y los modelos logísticos inferenciales usan errores agrupados por estudiante.

### 8.1 Descripción de la población


**Tabla 16:** Descriptivos por asignatura (medianas y rango intercuartílico; notas de evaluados).

| Asignatura  | n     | En riesgo | Prevalencia [IC 95 %] | G1 Md [RIC] | G3 Md [RIC] | Faltas Md [RIC] | No eval. G3 | Reprob. prev. |
|-------------|-------|-----------|-----------------------|-------------|-------------|-----------------|-------------|---------------|
| Matemáticas | 395   | 130       | 32,9 % [28,5; 37,7]   | 11 [8–13]   | 11 [9–14]   | 4 [0–8]         | 38          | 83            |
| Portugués   | 649   | 100       | 15,4 % [12,8; 18,4]   | 11 [10–13]  | 12 [10–14]  | 2 [0–6]         | 15          | 100           |
| Total       | 1 044 | 230       | 22,0 % [19,6; 24,6]   | –           | –           | –               | 53          | 183           |

Fuente: results/descriptivos.csv.

La prevalencia de reprobación final es el doble en Matemáticas (32,9 % [28,5; 37,7]) que en Portugués (15,4 % [12,8; 18,4]), con intervalos que no se solapan (Tabla 16). Las faltas son asimétricas (mediana muy inferior al máximo de 75), lo que justifica los métodos no paramétricos.

## 8.2 P1: evolución de la nota y combinaciones centro–signatura



**Figura 4:** Nota media por período, asignatura y escuela (evaluados; IC 95 %).


Fuente: `results/p1_medias_periodo_escuela.csv`.

**Tabla 17:** P1: cambio de la nota entre períodos (matrículas evaluadas en los tres períodos; Wilcoxon con Holm).

| Asignatura  | Comparación | n   | Dif. media [IC 95 % bootstrap] | $r_{rb}$ | $p$ (Holm) |
|-------------|-------------|-----|--------------------------------|----------|------------|
| Matemáticas | P1→P2       | 357 | 0,09 [-0,06; 0,24]             | 0,07     | 0,297      |
| Matemáticas | P2→P3       | 357 | 0,17 [0,08; 0,25]              | 0,29     | <0,001     |
| Matemáticas | P1→P3       | 357 | 0,25 [0,10; 0,41]              | 0,22     | 0,003      |
| Portugués   | P1→P2       | 633 | 0,24 [0,14; 0,33]              | 0,23     | <0,001     |
| Portugués   | P2→P3       | 633 | 0,43 [0,36; 0,51]              | 0,66     | <0,001     |
| Portugués   | P1→P3       | 633 | 0,67 [0,57; 0,78]              | 0,63     | <0,001     |

Fuente: `results/p1_pruebas_evolucion.csv`.  $r_{rb}$ : correlación biserial de rangos para muestras pareadas.

**Evolución.** La nota media aumenta ligeramente a lo largo del curso en ambas asignaturas (Figura 4, Tabla 17). En Portugués el cambio es sistemático (Friedman  $\chi^2 = 191,49$ ,  $p < 0,001$ ; W de Kendall = 0,151), con una mejora media de P1 a P3 de 0,67 puntos [0,57; 0,78]. En Matemáticas es menor y de magnitud despreciable ( $\chi^2 = 7,27$ ,  $p = 0,026$ ; W = 0,010; P1→P3 = 0,25 [0,10; 0,41]). En la práctica, ningún cambio altera la situación de aprobación de un estudiante típico (menos de un punto sobre 20). **Advertencia de interpretación:** el aumento se calcula sobre quienes siguen evaluados. Los que abandonan salen de la media (sesgo de supervivencia), y si se incluyeran sus ceros la media de Matemáticas *descendería* de 10,91 en P1 a 10,42 en P3. Este contraste justifica la regla R-08.



**Figura 5:** Tasa de reprobación final por asignatura y escuela (IC 95 % de Wilson).

Fuente: `results/p1_reprobacion_escuela_asignatura.csv`.

**Tabla 18:** Reprobación por asignatura y escuela.

| Asignatura  | Escuela              | n   | Reprob. | Tasa [IC 95 % Wilson] | Prioritaria |
|-------------|----------------------|-----|---------|-----------------------|-------------|
| Matemáticas | Gabriel Pereira      | 349 | 113     | 32.4 % [27,7; 37,5]   | Sí          |
| Matemáticas | Mousinho da Silveira | 46  | 17      | 37,0 % [24,5; 51,4]   | Sí          |
| Portugués   | Gabriel Pereira      | 423 | 32      | 7,6 % [5,4; 10,5]     | No          |
| Portugués   | Mousinho da Silveira | 226 | 68      | 30,1 % [24,5; 36,4]   | Sí          |

**Tabla 19:** Reprobación en P3 según el estado en P1.

| Asignatura  | Estado en P1 | n   | Reprueban en P3 | Tasa [IC 95 %]      |
|-------------|--------------|-----|-----------------|---------------------|
| Matemáticas | Reprueba P1  | 142 | 104             | 73,2 % [65,4; 79,8] |
| Matemáticas | Aprueba P1   | 253 | 26              | 10,3 % [7,1; 14,6]  |
| Portugués   | Reprueba P1  | 157 | 88              | 56,1 % [48,2; 63,6] |
| Portugués   | Aprueba P1   | 492 | 12              | 2,4 % [1,4; 4,2]    |

Fuente: `results/p1_reprobacion_escuela_asignatura.csv` y `results/p1_persistencia.csv`. “Prioritaria”: límite inferior del IC mayor que la tasa global (22,0 %).

**Combinaciones que exigen intervención.** Se definió como prioritaria una combinación cuyo límite inferior del IC de Wilson supera la tasa global. Tres de las cuatro cumplen el criterio (Tabla 18, Figura 5):

- Matemáticas en ambos centros: GP con 32,4 % [27,7; 37,5] y MS con 37,0 % [24,5; 51,4]. La diferencia entre centros no es significativa ( $\chi^2 = 0,39$ ,  $p$  Holm = 0,534,  $V = 0,031$ ).
- Portugués en Mousinho da Silveira: 30,1 % [24,5; 36,4] frente a 7,6 % en Gabriel Pereira. La diferencia de 22,5 puntos porcentuales es significativa y de tamaño moderado ( $\chi^2 = 57,33$ ,  $p$  Holm < 0,001,  $V = 0,297$ ).

El efecto de centro es, por tanto, específico de la asignatura. En los datos disponibles, la diferencia en Portugués no puede separarse de la composición del alumnado de cada centro (dato observacional). Además, la reprobación en P1 anticipa con fuerza la final (Tabla 19): reprueban al final el 73,2 % de quienes reprueban P1 en Matemáticas frente al 10,3 % de quienes lo aprueban, y en Portugués el 56,1 % frente al 2,4 %. Este hallazgo fundamenta el corte temprano.


### 8.3 P2: condiciones que distinguen el rendimiento sobre y bajo el promedio

Se compararon las matrículas evaluadas con  $G3$  por encima de la media de su asignatura con las que quedaron por debajo: 162 frente a 195 en Matemáticas y 276 frente a 358 en Portugués (Tabla 20, Figura 6).

**Tabla 20:** P2: comparación sobre/bajo el promedio por asignatura (MW: Mann-Whitney U con  $\delta$  de Cliff;  $\chi^2$ : chi-cuadrado con diferencia de proporciones y V de Cramér;  $p$  corregido por Holm).

| Asig.       | Variable                         | Sobre prom.   | Bajo prom.    | Prueba   | $p$ Holm | Efecto [IC 95 %]                  |
|-------------|----------------------------------|---------------|---------------|----------|----------|-----------------------------------|
| Matemáticas | Tiempo de estudio (1–4)          | 2 [1–3]       | 2 [2–2]       | MW       | 0,998    | 0,06 [-0,06; 0,17]                |
| Matemáticas | Faltas anuales                   | 2 [0–6]       | 4 [2–10]      | MW       | 0,001    | -0,23 [-0,34; -0,11]              |
| Matemáticas | Reprobaciones previas            | 0 [0–0]       | 0 [0–0]       | MW       | <0,001   | -0,16 [-0,23; -0,09]              |
| Matemáticas | Refuerzo escolar (sí)            | 5,6 %         | 21,0 %        | $\chi^2$ | <0,001   | -15,5 pp [-22,0; -8,8]; $V=0,222$ |
| Matemáticas | Clases pagadas (sí)              | 45,7 %        | 50,8 %        | $\chi^2$ | 0,998    | -5,1 pp [-16,1; 4,9]; $V=0,051$   |
| Matemáticas | Aspira a educación superior (sí) | 97,5 %        | 94,9 %        | $\chi^2$ | 0,988    | 2,7 pp [-1,2; 6,6]; $V=0,068$     |
| Matemáticas | Minutos LMS en P1 [SIM]          | 276 [134–540] | 270 [114–463] | MW       | 0,998    | 0,06 [-0,06; 0,18]                |
| Matemáticas | Eventos LMS en P1 [SIM]          | 14 [8–24]     | 13 [7–23]     | MW       | 0,998    | 0,07 [-0,05; 0,19]                |
| Portugués   | Tiempo de estudio (1–4)          | 2 [2–3]       | 2 [1–2]       | MW       | <0,001   | 0,26 [0,17; 0,33]                 |
| Portugués   | Faltas anuales                   | 2 [0–4]       | 4 [0–6]       | MW       | <0,001   | -0,22 [-0,30; -0,14]              |
| Portugués   | Reprobaciones previas            | 0 [0–0]       | 0 [0–0]       | MW       | <0,001   | -0,22 [-0,27; -0,18]              |
| Portugués   | Refuerzo escolar (sí)            | 7,2 %         | 13,1 %        | $\chi^2$ | 0,034    | -5,9 pp [-10,5; -1,4]; $V=0,095$  |
| Portugués   | Clases pagadas (sí)              | 4,3 %         | 7,3 %         | $\chi^2$ | 0,125    | -2,9 pp [-6,6; 0,5]; $V=0,061$    |
| Portugués   | Aspira a educación superior (sí) | 99,3 %        | 82,7 %        | $\chi^2$ | <0,001   | 16,6 pp [12,7; 20,7]; $V=0,273$   |
| Portugués   | Minutos LMS en P1 [SIM]          | 278 [138–563] | 195 [81–411]  | MW       | <0,001   | 0,19 [0,10; 0,27]                 |
| Portugués   | Eventos LMS en P1 [SIM]          | 15 [8–25]     | 11 [5–20]     | MW       | <0,001   | 0,21 [0,11; 0,29]                 |

Fuente: `results/p2_condiciones.csv`. Resumen: mediana [RIC] o porcentaje. [SIM] = variable simulada.



$\delta$  de Cliff (grupo sobre el promedio – grupo bajo el promedio), IC 95 % bootstrap

**Figura 6:** Tamaño de efecto ( $\delta$  de Cliff, IC 95 % *bootstrap*) de las variables ordinales y numéricas en P2.

Fuente: `results/p2_condiciones.csv`.

### Interpretación (datos reales).

- En ambas asignaturas, quienes quedan bajo el promedio tienen **más faltas** ( $\delta = -0,23$  en MAT;  $-0,22$  en POR) y **más reprobaciones previas** ( $\delta = -0,16$  y  $-0,22$ ). Son efectos pequeños pero consistentes.
- El **tiempo de estudio** distingue en Portugués ( $\delta = 0,26$ ), no en Matemáticas ( $\delta = 0,06$ ).
- La aspiración a educación superior es mucho más frecuente sobre el promedio en Portugués ( $V = 0,273$ ).
- El **refuerzo escolar** es *más* frecuente en el grupo bajo el promedio ( $V = 0,222$  en MAT). Esto refleja que el refuerzo se asigna a quien ya tiene dificultades (causalidad inversa), no que perjudique. Es un ejemplo de por qué la asociación no implica causalidad.
- Las clases pagadas no distinguen.

**Variables simuladas.** Los minutos LMS<sup>SIM</sup> muestran  $\delta = 0,19$  en Portugués y  $0,06$  en Matemáticas. No es un hallazgo: el generador hace depender el LMS del tiempo de estudio y de la aspiración a estudios superiores, que en Portugués sí se asocian al rendimiento. La señal simulada solo reproduce, atenuada, la de esas covariables reales.


## 8.4 Pregunta principal: combinación de factores y acompañamiento asociado

Se definieron tres factores: *alta inasistencia* (cuartil superior de faltas de la asignatura; real), *reprobaciones previas* (1 o más; real) y *bajo involucramiento LMS* (cuartil inferior de minutos LMS en P1; simulado). Conforme a R-09, el análisis usa las 991 matrículas con faltas confiables.

**Tabla 21:** Perfiles de riesgo: reprobación final y acompañamiento asociado (columnas [SIM] simuladas).

| Alta inasist. | Reprob. prev. | Bajo LMS [SIM] | n   | Reprobación [IC 95 %] | Con alerta [SIM] | Tutorías/matr. [SIM] | Alerta cerrada [SIM] |
|---------------|---------------|----------------|-----|-----------------------|------------------|----------------------|----------------------|
| No            | Sí            | Sí             | 42  | 50 % [35,5; 64,5]     | 81 %             | 1,50                 | 36 %                 |
| Sí            | Sí            | Sí             | 30  | 50 % [33,2; 66,8]     | 53 %             | 1,33                 | 37 %                 |
| Sí            | Sí            | No             | 41  | 49 % [34,3; 63,5]     | 51 %             | 0,98                 | 37 %                 |
| No            | Sí            | No             | 41  | 39 % [25,7; 54,3]     | 59 %             | 1,07                 | 39 %                 |
| Sí            | No            | Sí             | 44  | 27 % [16,3; 41,8]     | 32 %             | 0,30                 | 20 %                 |
| Sí            | No            | No             | 164 | 18 % [12,6; 24,2]     | 18 %             | 0,39                 | 12 %                 |
| No            | No            | Sí             | 124 | 15 % [9,4; 21,8]      | 26 %             | 0,51                 | 19 %                 |
| No            | No            | No             | 505 | 9 % [6,9; 11,9]       | 14 %             | 0,31                 | 9 %                  |

Fuente: `results/principal_perfiles.csv`; matrículas con faltas confiables.



| Muestra                             | n    | Factor                      | OR [IC 95 %]      | p      |
|-------------------------------------|------|-----------------------------|-------------------|--------|
| faltas confiables (principal)       | 991  | alta_inasistencia           | 1,77 [1,22; 2,55] | 0,003  |
| faltas confiables (principal)       | 991  | reprob_previas              | 5,58 [3,71; 8,37] | <0,001 |
| faltas confiables (principal)       | 991  | Portugués (vs. Matemáticas) | 0,45 [0,32; 0,63] | <0,001 |
| todas las matrículas (sensibilidad) | 1044 | alta_inasistencia           | 1,20 [0,83; 1,72] | 0,334  |
| todas las matrículas (sensibilidad) | 1044 | reprob_previas              | 6,87 [4,73; 9,98] | <0,001 |
| todas las matrículas (sensibilidad) | 1044 | Portugués (vs. Matemáticas) | 0,37 [0,27; 0,50] | <0,001 |

**Figura 7:** Gradiente de reprobación según el número de factores reales (izquierda) y odds ratios ajustados con errores agrupados por estudiante (derecha).


Fuente: `results/principal_gradiente.csv` y `results/principal_or.csv`.

**Interpretación.** La reprobación crece de forma monótona con el número de factores reales: 10,2 % [8,0; 12,8] sin factores ( $n = 629$ ), 26,8 % [22,0; 32,2] con uno ( $n = 291$ ) y 49,3 % [38,0; 60,7] con ambos ( $n = 71$ ) (Figura 7). Ajustando por asignatura, las reprobaciones previas multiplican las odds por 5,58 [3,71; 8,37] y la alta inasistencia por 1,77 [1,22; 2,55]. La regla R-09 importa: si se incluyen los no evaluados con 0 faltas no confiables, el OR de inasistencia se atenúa a 1,20 [0,83; 1,72] y deja de ser significativo, lo que llevaría a una conclusión errónea. En la Tabla 21, los perfiles con reprobaciones previas tienen tasas de reprobación de entre 39 % y 50 %, con independencia del LMS. El factor  $LMS^{SIM}$  no muestra un patrón propio, consistente con su proceso generador. En cuanto al acompañamiento<sup>SIM</sup>, los perfiles de mayor riesgo concentran más alertas y tutorías, porque la regla simulada las dispara con  $G1 < 10$ . AG-04 muestra que el 66,5 % de las alertas de nivel medio y el 71,3 % de las de nivel alto tienen una tutoría posterior, y que ninguna de nivel bajo la tiene. Esto demuestra la capacidad del pipeline para responder este tipo de consulta, pero no mide la eficacia de las tutorías.

## 8.5 Modelo de predicción temprana

**Diseño.** Se definieron escenarios de información creciente: C, solo antecedentes al matricular (sin notas); A, corte P1, que es C más G1 y es el escenario principal; y B, corte P2, que añade G2. Se comparan una línea base (probabilidad a priori), una regresión logística (interpretable) y dos modelos no lineales: *random forest* (Breiman, 2001) y *gradient boosting* (Friedman, 2001). La

evaluación usa validación cruzada estratificada y agrupada por estudiante (5 pliegues) en entrenamiento, y una evaluación final única en el conjunto de prueba reservado (212 matrículas, 51 en riesgo, 24,1 %). Por el desbalance, se reportan AUC-PR, recall, precisión, F1 y Brier además del AUC-ROC (Saito & Rehmsmeier, 2015). El umbral de decisión se fijó en entrenamiento, con predicciones fuera de pliegue, como el mayor umbral que logra un recall de al menos 0,80, porque en alerta temprana omitir a un estudiante en riesgo cuesta más que una derivación innecesaria.



**Figura 8:** Curvas ROC y precisión-recall en prueba, escenario A (corte P1).


Fuente: `src/analysis.py::modelado`.

**Resultados.** La Tabla 22 reúne las métricas de todos los escenarios y modelos, y la Figura 8 muestra las curvas del escenario principal. En el escenario A, la regresión logística obtiene un AUC-ROC en prueba de 0,948 [0,918; 0,972] (CV: 0,924), un AUC-PR de 0,853 (línea base: 0,241) y, con el umbral preespecificado, recall 0,902, precisión 0,667, especificidad 0,857, F1 0,767 y Brier 0,080 (línea base: 0,183). La matriz de confusión en prueba es VP = 46, FN = 5, FP = 23 y VN = 138: se detectan 46 de los 51 casos en riesgo, a costa de 23 derivaciones innecesarias. Los modelos no lineales no superan a la logística (*random forest* 0,940, *gradient boosting* 0,944), así que se prefiere el modelo interpretable. El valor de la información temprana es claro: pasar de C (sin notas, AUC 0,738) a A (con G1) añade  $\Delta\text{AUC} = 0,211$  [0,145; 0,283]. Esperar a P2 añade solo 0,036 [0,017; 0,058] más, y a cambio se pierde un período de intervención. El rendimiento es similar por centro y asignatura (Tabla 24), sin degradación en el centro minoritario.

**Tabla 22:** Métricas de los modelos por escenario (CV: media  $\pm$  DE en 5 pliegues agrupados; test: conjunto reservado, IC 95 % *bootstrap* por estudiante).

| Escenario               | Modelo              | AUC-ROC CV        | AUC-PR CV | AUC-ROC test [IC 95 %] | AUC-PR | Recall | Precisión | F1    | Brier |
|-------------------------|---------------------|-------------------|-----------|------------------------|--------|--------|-----------|-------|-------|
| A: corte P1 (principal) | Línea base (prior)  | 0,500 $\pm$ 0,000 | 0,215     | 0,500 [0,500; 0,500]   | 0,241  | 0,000  | 0,000     | 0,000 | 0,183 |
| A: corte P1 (principal) | Regresión logística | 0,924 $\pm$ 0,011 | 0,762     | 0,948 [0,918; 0,972]   | 0,853  | 0,902  | 0,667     | 0,767 | 0,080 |
| A: corte P1 (principal) | Random forest       | 0,921 $\pm$ 0,018 | 0,739     | 0,940 [0,904; 0,969]   | 0,845  | 0,882  | 0,714     | 0,789 | 0,097 |
| A: corte P1 (principal) | Gradient boosting   | 0,925 $\pm$ 0,007 | 0,761     | 0,944 [0,915; 0,968]   | 0,830  | 0,922  | 0,671     | 0,777 | 0,083 |
| C: sin notas            | Regresión logística | 0,775 $\pm$ 0,029 | 0,481     | 0,738 [0,664; 0,804]   | 0,532  | 0,686  | 0,376     | 0,486 | 0,158 |
| C: sin notas            | Random forest       | 0,799 $\pm$ 0,048 | 0,508     | 0,750 [0,676; 0,817]   | 0,563  | 0,667  | 0,378     | 0,482 | 0,154 |
| C: sin notas            | Gradient boosting   | 0,785 $\pm$ 0,030 | 0,490     | 0,762 [0,689; 0,824]   | 0,557  | 0,745  | 0,358     | 0,484 | 0,153 |
| C + LMS [SIM]           | Regresión logística | 0,774 $\pm$ 0,022 | 0,480     | 0,737 [0,660; 0,805]   | 0,520  | 0,667  | 0,366     | 0,472 | 0,159 |
| C + LMS [SIM]           | Random forest       | 0,800 $\pm$ 0,026 | 0,521     | 0,755 [0,674; 0,829]   | 0,553  | 0,745  | 0,380     | 0,503 | 0,153 |
| C + LMS [SIM]           | Gradient boosting   | 0,777 $\pm$ 0,028 | 0,462     | 0,777 [0,707; 0,839]   | 0,575  | 0,784  | 0,381     | 0,513 | 0,148 |
| A + LMS [SIM]           | Regresión logística | 0,923 $\pm$ 0,010 | 0,746     | 0,949 [0,919; 0,972]   | 0,853  | 0,902  | 0,657     | 0,760 | 0,081 |
| A + LMS [SIM]           | Random forest       | 0,921 $\pm$ 0,016 | 0,750     | 0,945 [0,911; 0,973]   | 0,864  | 0,882  | 0,682     | 0,769 | 0,096 |
| A + LMS [SIM]           | Gradient boosting   | 0,921 $\pm$ 0,007 | 0,745     | 0,948 [0,920; 0,972]   | 0,846  | 0,902  | 0,657     | 0,760 | 0,080 |
| A + faltas anuales      | Regresión logística | 0,925 $\pm$ 0,011 | 0,766     | 0,945 [0,912; 0,970]   | 0,847  | 0,882  | 0,692     | 0,776 | 0,080 |
| A + faltas anuales      | Random forest       | 0,923 $\pm$ 0,017 | 0,753     | 0,942 [0,906; 0,971]   | 0,860  | 0,882  | 0,726     | 0,796 | 0,094 |
| A + faltas anuales      | Gradient boosting   | 0,925 $\pm$ 0,020 | 0,751     | 0,953 [0,927; 0,975]   | 0,855  | 0,882  | 0,714     | 0,789 | 0,077 |
| B: corte P2             | Regresión logística | 0,962 $\pm$ 0,016 | 0,892     | 0,984 [0,969; 0,995]   | 0,958  | 0,902  | 0,836     | 0,868 | 0,044 |
| B: corte P2             | Random forest       | 0,962 $\pm$ 0,012 | 0,880     | 0,988 [0,975; 0,996]   | 0,965  | 0,882  | 0,882     | 0,882 | 0,055 |
| B: corte P2             | Gradient boosting   | 0,962 $\pm$ 0,018 | 0,890     | 0,984 [0,968; 0,996]   | 0,960  | 0,902  | 0,885     | 0,893 | 0,041 |

Fuente: `results/modelo_metricas.csv`. Recall, precisión y F1 con el umbral fijado en entrenamiento (recall OOF  $\geq 0,80$ ).



**Figura 9:** Calibración en prueba (izquierda) e importancia por permutación del mejor modelo no lineal en CV (derecha), escenario A.

Fuente: `results/modelo_importancia_permutacion.csv`.

**Tabla 23:** Odds ratios del modelo logístico parsimonioso (corte P1; entrenamiento; errores agrupados por estudiante).

| Predictor (corte P1)               | OR [IC 95 %]      | <i>p</i> |
|------------------------------------|-------------------|----------|
| Nota P1 ( <i>G1</i> ), por punto   | 0,39 [0,32; 0,47] | <0,001   |
| Reprobaciones previas (por unidad) | 1,29 [0,84; 1,97] | 0,239    |
| Tiempo de estudio (por nivel)      | 1,26 [0,90; 1,77] | 0,176    |
| Edad (por año)                     | 0,98 [0,78; 1,23] | 0,871    |
| Salidas con amigos (1–5)           | 1,24 [0,95; 1,60] | 0,108    |
| Alcohol fin de semana (1–5)        | 0,98 [0,78; 1,24] | 0,873    |
| Portugués (vs. Matemáticas)        | 0,29 [0,16; 0,50] | <0,001   |
| Mousinho da Silveira (vs. GP)      | 1,39 [0,76; 2,54] | 0,293    |
| Sexo masculino                     | 1,42 [0,82; 2,47] | 0,215    |
| Aspira a educación superior        | 0,42 [0,19; 0,94] | 0,035    |
| Refuerzo escolar                   | 0,94 [0,36; 2,44] | 0,894    |
| Zona rural                         | 0,95 [0,53; 1,69] | 0,852    |

Fuente: `results/modelo_odds_ratios.csv` y `results/modelo_estratos.csv`. Predictores del modelo parsimonioso preespecificados.

**Tabla 24:** Desempeño del modelo A (logística) por estrato en prueba.

| Estrato    | Valor                | n test | Prevalencia | AUC-ROC | Recall | Precisión |
|------------|----------------------|--------|-------------|---------|--------|-----------|
| escuela    | Gabriel Pereira      | 158    | 19,6 %      | 0,947   | 0,903  | 0,596     |
| escuela    | Mousinho da Silveira | 54     | 37,0 %      | 0,963   | 0,900  | 0,818     |
| asignatura | Matemáticas          | 82     | 35,4 %      | 0,915   | 0,897  | 0,634     |
| asignatura | Portugués            | 130    | 16,9 %      | 0,966   | 0,909  | 0,714     |

**Interpretación.** Cada punto adicional en *G1* multiplica las odds de reprobación por 0,387 [0,317; 0,472], es decir, las reduce en torno al 61 % por punto (Tabla 23). Condicionado a *G1*, cursar Portugués reduce las odds (OR 0,29 [0,16; 0,50]), igual que aspirar a educación superior (OR 0,42 [0,19; 0,94]). Las reprobaciones previas y el centro dejan de ser significativos una vez que se conoce *G1* (centro MS: OR 1,39 [0,76; 2,54]), porque su efecto ya está incorporado en esa nota. La importancia por permutación coincide con esta lectura: permutar *G1* reduce el AUC en 0,414, y la siguiente variable (asignatura) solo en 0,014. La calibración de la logística es aceptable (Figura 9); el *random forest* subestima las probabilidades altas. Por eso, para comunicar probabilidades se recomienda la logística.

## 8.6 Sensibilidad: datos reales frente a datos simulados

**Tabla 25:** Análisis de sensibilidad: cambio de AUC-ROC en prueba al añadir o quitar información (IC 95 % *bootstrap* pareado por estudiante).

| Modelo              | Comparación               | $\Delta$ AUC-ROC test [IC 95 % bootstrap pareado] |
|---------------------|---------------------------|---------------------------------------------------|
| Regresión logística | A mas sim - A corte P1    | 0,000 [-0,004; 0,004]                             |
| Regresión logística | C mas sim - C matricula   | -0,000 [-0,015; 0,012]                            |
| Regresión logística | A mas faltas - A corte P1 | -0,003 [-0,010; 0,002]                            |
| Regresión logística | B corte P2 - A corte P1   | 0,036 [0,017; 0,058]                              |
| Regresión logística | A corte P1 - C matricula  | 0,211 [0,145; 0,283]                              |
| Random forest       | A mas sim - A corte P1    | 0,005 [-0,005; 0,015]                             |
| Random forest       | C mas sim - C matricula   | 0,005 [-0,029; 0,039]                             |
| Random forest       | A mas faltas - A corte P1 | 0,001 [-0,008; 0,010]                             |
| Random forest       | B corte P2 - A corte P1   | 0,047 [0,021; 0,079]                              |
| Random forest       | A corte P1 - C matricula  | 0,190 [0,127; 0,261]                              |
| Gradient boosting   | A mas sim - A corte P1    | 0,004 [-0,006; 0,015]                             |
| Gradient boosting   | C mas sim - C matricula   | 0,016 [-0,015; 0,048]                             |
| Gradient boosting   | A mas faltas - A corte P1 | 0,009 [-0,002; 0,022]                             |
| Gradient boosting   | B corte P2 - A corte P1   | 0,040 [0,018; 0,065]                              |
| Gradient boosting   | A corte P1 - C matricula  | 0,182 [0,122; 0,250]                              |

Fuente: `results/modelo_sensibilidad.csv`.

- **Con y sin variables simuladas.** Añadir las cuatro variables  $LMS^{\text{SIM}}$  del corte P1 no cambia el desempeño:  $\Delta AUC = 0,000 [-0,004; 0,004]$  en A y  $-0,000 [-0,015; 0,012]$  en C (logística). Todos los intervalos incluyen el cero en los tres algoritmos (Tabla 25). Es el resultado esperado de un generador no circular: el LMS simulado no contiene información sobre  $G3$  más allá de las covariables reales que ya están en el modelo.
- **Contrafactual didáctico de circularidad.** Si el LMS se hubiera generado “correlacionado con el riesgo real”, como proponía el avance (aquí, minutos  $\propto e^{0,15 G3}$ ), el escenario C pasaría de AUC 0,738 a 0,877. Sería una mejora ficticia de 0,139, producida solo por la construcción de los datos. Esta cifra cuantifica el riesgo que motivó el rediseño del generador.
- **Faltas anuales.** Añadirlas al modelo temprano no mejora el AUC ( $-0,003 [-0,010; 0,002]$ ). Por tanto, excluirlas por fuga temporal (L-02) no tiene costo.

**Separación de hallazgos.** Todos los hallazgos sustantivos (§8.2, §8.3, §8.4 en sus factores reales y §8.5) provienen de datos reales. Las cifras sobre LMS, tutorías, alertas y texto son demostraciones de que el pipeline integra, valida y consulta evidencia heterogénea.

## 8.7 Componente no estructurado: texto libre de las alertas

Las 575 notas de orientación<sup>SIM</sup> se normalizaron (minúsculas, expansión de abreviaturas como “est.” → “estudiante”, eliminación de tildes, puntuación y espacios repetidos), se tokenizaron sin palabras vacías y se categorizaron por léxico en académico, asistencia, familiar, conducta y motivación (`transform_synthetic.py::categorizar`). Los resultados se guardan en el propio documento (`texto_normalizado, categoria`), se indexan con un índice de texto en español y se agregan con AG-06 (Tabla 26). La Tabla 27 muestra ejemplos de la normalización y la Tabla 33 (Anexo F) los términos más frecuentes. La exactitud frente a la categoría verdadera del generador es 100,0 %. **Este valor no mide la capacidad de generalizar:** el léxico se construyó conociendo las plantillas del generador, por lo que solo demuestra que la transformación está bien implementada. Con notas

reales se necesitaría una muestra etiquetada por orientadores y un clasificador supervisado evaluado en datos no vistos.

**Tabla 26:** AG-06<sup>SIM</sup>: categoría inferida  $\times$  nivel de alerta.

| Categoría inferida | Alto | Medio | Bajo | Total |
|--------------------|------|-------|------|-------|
| academico          | 77   | 122   | 16   | 215   |
| asistencia         | 51   | 63    | 3    | 117   |
| conducta           | 29   | 42    | 2    | 73    |
| familiar           | 23   | 50    | 5    | 78    |
| motivacion         | 36   | 50    | 6    | 92    |

**Tabla 27:** Ejemplos de normalización<sup>SIM</sup>.

| Texto original [SIM]                                                                       | Texto normalizado                                                                        | Categoría  |
|--------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|------------|
| Registro de asistencia irregular durante el período; se solicita justificación.            | registro de asistencia irregular durante el periodo se solicita justificacion            | asistencia |
| Inasistencias reiteradas a clase; se contacta al representante para justificar las faltas. | inasistencias reiteradas a clase se contacta al representante para justificar las faltas | asistencia |
| Registro de asistencia irregular durante el período; se solicita justificación.            | registro de asistencia irregular durante el periodo se solicita justificacion            | asistencia |

Fuente: `results/mongo_AG-06.csv` y `results/texto_ejemplos.csv`. Datos simulados.

## 8.8 Utilidad y limitaciones de los resultados

**Utilidad.** Al cierre de P1, una regla basada en el modelo A identificaría al 0,902 de los estudiantes que reprobarán (recall), y el 0,667 de las derivaciones serían correctas (precisión). Es un criterio operativo y explicable para orientar tutorías.

### Limitaciones.

- (I) Los datos son *observacionales*: ninguna asociación es causal.
- (II) La población es de dos centros portugueses en 2005–2006; la validez externa es limitada.
- (III) *G1* domina la predicción; el modelo no identifica a quien reprobará pese a aprobar P1 (10,3 % en MAT).
- (IV) Las fuentes F2 y F3 son simuladas: su utilidad predictiva real está por demostrar.
- (V) El conjunto de prueba es pequeño (212 matrículas), de ahí la anchura de los IC.
- (VI) La identidad tiene 5 posibles falsos negativos.
- (VII) El umbral de recall 0,80 es una decisión de política que debería fijar la institución según su capacidad de tutoría.

## 9. Conclusiones y recomendaciones

### 9.1 Conclusiones

- Arquitectura.** El almacenamiento híbrido es coherente con el problema. PostgreSQL en 3FN garantiza la integridad del registro académico: 11 de 11 controles superados. MongoDB, con validadores `$jsonSchema` y `$expr`, modela la evidencia anidada y variable con cobertura total. Parquet sirve de contrato con la capa analítica.
- Calidad.** Los principales problemas del registro UCI eran semánticos: identidad, notas 0 y faltas no confiables. La regla de identidad en dos etapas corrigió las cifras del avance a 674 estudiantes, 1 044 matrículas y 3 132 calificaciones, y recuperó 16 matrículas reales que se habían perdido. Las reglas sobre datos simulados detectaron exactamente los defectos inyectados.
- P1.** La reprobación se concentra en Matemáticas (ambos centros) y en Portugués en Mou-sinho da Silveira (30,1 %). La nota media apenas varía a lo largo del curso cuando se excluyen los abandonos.

4. **P2 y pregunta principal.** Las reprobaciones previas y la inasistencia distinguen el bajo rendimiento y se acumulan: la reprobación pasa de 10,2 % sin factores a 49,3 % con ambos.
5. **Predicción temprana.** Con información del primer período, sin  $G3$ , sin faltas anuales y sin compartir estudiantes entre entrenamiento y prueba, un modelo logístico interpretable alcanza un AUC de 0,948 y un recall de 0,902. La nota  $G1$  aporta casi toda la señal.
6. **Datos simulados.** No aportan información predictiva ( $\Delta\text{AUC} = 0,000$ ), como exige un generador no circular. El contrafactual muestra que un generador circular habría fabricado una mejora de 0,139 en el AUC.
7. **Escalabilidad.** Spark no está justificado. El benchmark procesa 23 798 500 eventos en 2,67 s en un solo nodo, y el caso real está 3,5 órdenes de magnitud por debajo de ese umbral.

## 9.2 Recomendaciones para la coordinación y la orientación

- Institucionalizar una **alerta al cierre del primer período**: toda matrícula con  $G1 < 10$  o con probabilidad del modelo A superior al umbral se deriva a tutoría antes de enero.
- Priorizar **Matemáticas** en ambos centros y **Portugués en Mousinho da Silveira**.
- Dar seguimiento específico a los estudiantes con **reprobaciones previas** desde la matrícula (escenario C), antes incluso de la primera nota.
- Registrar la asistencia por período, no solo anual, y codificar explícitamente los abandonos, en lugar de registrar notas 0 con 0 faltas.

## 9.3 Mejoras y próximos pasos

1. Sustituir F2 y F3 por exportaciones reales del LMS y del departamento de orientación, reutilizando validadores y reglas, y repetir la sensibilidad.
2. Evaluar el efecto de las tutorías con un diseño cuasiexperimental (p. ej., regresión discontinua en el umbral  $G1 = 10$ ).
3. Validar el modelo en una cohorte posterior (validación temporal) y recalibrarlo por centro.
4. Añadir un clasificador supervisado de texto entrenado con notas etiquetadas.
5. Orquestar el pipeline con un planificador (p. ej., Airflow) y publicar el tablero de alertas desde la colección `alertas_riesgo`.

## 10. Evidencias técnicas

La Tabla 28 describe la estructura del repositorio.

**Repositorio:** <https://github.com/Crisolis517/PIF>

**Copia adjunta:** `proyecto-integrador.zip`. Contiene la estructura completa de la Tabla 28: datos, código, consultas, resultados, registros de ejecución y la fuente de este informe. Se reproduce con las instrucciones siguientes.

**Tabla 28:** Estructura del repositorio y artefactos entregados.

| Ruta                                       | Contenido                                                                                                                                         |
|--------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------|
| run_pipeline.py                            | Punto de entrada único (etapas 1–11).                                                                                                             |
| docker-compose.yml,<br>.env.example        | PostgreSQL 16 y MongoDB 8; variables de conexión sin secretos.                                                                                    |
| requirements.txt,<br>requirements-lock.txt | Versiones fijadas y entorno congelado.                                                                                                            |
| data/raw/                                  | student-mat.csv, student-por.csv (UCI) y synthetic/ (JSON crudos + verdad del generador).                                                         |
| data/staging/                              | Tablas 3FN, evidencia de identidad, documentos Mongo, cuarentena.                                                                                 |
| data/processed/                            | dataset_analitico.parquet (+ .csv), diccionario_datos.csv, linaje.csv, mapeo_avance_final.csv.                                                    |
| sql/                                       | 01_ddl.sql, 02_vistas_seguridad.sql, 03_integridad.sql, 04_analiticas.sql.                                                                        |
| mongo/                                     | validadores.json, indices.json, pipelines.json (ejecutables también desde mongosh).                                                               |
| src/                                       | config, tracking, extract, transform, generate_synthetic, transform_synthetic, load, integrate, analysis, benchmark_escalabilidad, report_tables. |
| tests/test_pipeline.py                     | 17 pruebas pytest.                                                                                                                                |
| notebooks/analisis.ipynb                   | Notebook ejecutado: consultas SQL y pipelines Mongo en vivo, reproducción del AUC principal.                                                      |
| results/, logs/                            | Salidas de consultas, pruebas y modelos; conteos por etapa, reglas y checksums.                                                                   |
| informe/                                   | main.tex, generated/ (tablas y macros), figuras/, PDF final.                                                                                      |

## Instrucciones de ejecución.

```

cp .env.example .env && docker compose up -d --wait          # PostgreSQL 16 + MongoDB 8
python3 -m venv .env && .env/bin/pip install -r requirements.txt
.env/bin/python run_pipeline.py --informe                     # pipeline completo + PDF (~90 s)
.env/bin/python -m pytest -q                                 # 17 pruebas

```

**Datos de ejemplo.** El Listado 4 muestra un documento real de la colección `seguimiento_riesgo` tras la carga, recortado a dos eventos. El Anexo F reproduce una alerta con su historial y sus notas.

**Listado 4:** Documento de `seguimiento_riesgo`<sup>SIM</sup> (estudiante 1, período P1; recortado a dos eventos; generado desde `results/mongo_documentos_ejemplo.json`).

```

{
  "estudiante_id": 1,
  "periodo": "P1",
  "periodo_inicio": "2005-09-15T00:00:00",
  "periodo_fin": "2005-12-16T23:59:59",
  "interacciones_lms": [
    {
      "evento_id": "EV-0000003",
      "asignatura": "MAT",
      "fecha": "2005-09-19T16:24:00",
      "tipo": "tarea",
      "duracion_min": 17,
      "revisada": true
    },
    {
      "evento_id": "EV-0000050",
      "asignatura": "POR",
      "fecha": "2005-09-22T21:36:00",
      "tipo": "foro",
      "duracion_min": 32
    }
  ],
  "tutorias": [],
  "es_simulado": true,
  "fuente": "generate_synthetic v1.0 (seed=42)"
}

```

## Referencias

- Apache Software Foundation. (2024). *Apache Parquet documentation*. <https://parquet.apache.org/docs/>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Cliff, N. (1993). Dominance statistics: Ordinal analyses to answer ordinal questions. *Psychological Bulletin*, 114(3), 494–509. <https://doi.org/10.1037/0033-2909.114.3.494>
- Cortez, P. (2008). *Student performance* [Conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5TG7T>
- Cortez, P., & Silva, A. M. G. (2008). Using data mining to predict secondary school student performance. En A. Brito & J. Teixeira (Eds.), *Proceedings of 5th Future Business Technology Conference (FUBUTEC 2008)* (pp. 5–12). EUROSIS-ETI.
- Elmasri, R., & Navathe, S. B. (2016). *Fundamentals of database systems* (7.<sup>a</sup> ed.). Pearson.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232. <https://doi.org/10.1214/aos/1013203451>
- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4), Artículo 15. <https://doi.org/10.1145/2382577.2382579>
- Kleppmann, M. (2017). *Designing data-intensive applications*. O'Reilly Media.
- MongoDB, Inc. (2024). *MongoDB manual: Aggregation pipeline and schema validation*. <https://www.mongodb.com/docs/manual/>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Romano, J., Kromrey, J. D., Coraggio, J., & Skowronek, J. (2006). *Appropriate statistics for ordinal level data: Should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys?* [Ponencia]. Annual Meeting of the Florida Association of Institutional Research, Cocoa Beach, FL, Estados Unidos.
- Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), Artículo e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. En *Proceedings of the 9th Python in Science Conference* (pp. 92–96). <https://doi.org/10.25080/MAJORA-92bf1922-011>
- The PostgreSQL Global Development Group. (2024). *PostgreSQL 16 documentation*. <https://www.postgresql.org/docs/16/>
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158), 209–212. <https://doi.org/10.1080/01621459.1927.10502953>
- Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., Meng, X., Rosen, J., Venkataraman, S., Franklin, M. J., Ghodsi, A., Gonzalez, J., Shenker, S., Zaharia, M., & Stoica, I. (2016). Apache Spark: A unified engine for big data processing. *Communications of the ACM*, 59(11), 56–65. <https://doi.org/10.1145/2934664>

## A. DDL completo (PostgreSQL)

Listado 5: `sql/01_ddl.sql`.

```

-- =====
-- 01_ddl.sql - Modelo relacional 3FN del registro académico (fuente F1, UCI)
-- Compatible con PostgreSQL 16 (probado también en PostgreSQL 18).
-- Esquema: academico. Seis tablas: escuela, asignatura, periodo, estudiante,
-- matricula (resuelve N:M -estudianteasignatura) y calificacion (1FN de -G1G3).
-- =====

DROP SCHEMA IF EXISTS academico CASCADE;
CREATE SCHEMA academico;
SET search_path TO academico;

-- Catálogo de centros -----
CREATE TABLE escuela (
    escuela_id SMALLINT PRIMARY KEY,
    codigo CHAR(2) NOT NULL UNIQUE CHECK (codigo IN ('GP', 'MS')),
    nombre VARCHAR(40) NOT NULL
);

-- Catálogo de asignaturas -----
CREATE TABLE asignatura (
    asignatura_id SMALLINT PRIMARY KEY,
    codigo CHAR(3) NOT NULL UNIQUE CHECK (codigo IN ('MAT', 'POR')),
    nombre VARCHAR(40) NOT NULL
);

-- Períodos lectivos -20052006: P1<->G1, P2<->G2, P3<->G3 (nota final) -----
CREATE TABLE periodo (
    periodo_id SMALLINT PRIMARY KEY,
    codigo CHAR(2) NOT NULL UNIQUE CHECK (codigo IN ('P1', 'P2', 'P3')),
    nombre VARCHAR(60) NOT NULL,
    orden SMALLINT NOT NULL UNIQUE CHECK (orden BETWEEN 1 AND 3),
    nota_uci CHAR(2) NOT NULL UNIQUE CHECK (nota_uci IN ('G1', 'G2', 'G3')),
    fecha_inicio DATE NOT NULL,
    fecha_fin DATE NOT NULL,
    CHECK (fecha_fin > fecha_inicio)
);

-- Estudiante: atributos personales (no dependen de la asignatura) -----
CREATE TABLE estudiante (
    estudiante_id INTEGER PRIMARY KEY,
    escuela_id SMALLINT NOT NULL REFERENCES escuela (escuela_id),
    sexo CHAR(1) NOT NULL CHECK (sexo IN ('F', 'M')),
    edad SMALLINT NOT NULL CHECK (edad BETWEEN 15 AND 22),
    zona VARCHAR(6) NOT NULL CHECK (zona IN ('Urbana', 'Rural')),
    tamano_familia VARCHAR(3) NOT NULL CHECK (tamano_familia IN ('<=3', '>3')),
    estado_padres VARCHAR(9) NOT NULL CHECK (estado_padres IN ('Juntos', 'Separados')),
    educ_madre SMALLINT NOT NULL CHECK (educ_madre BETWEEN 0 AND 4),
    educ_padre SMALLINT NOT NULL CHECK (educ_padre BETWEEN 0 AND 4),
    trabajo_madre VARCHAR(10) NOT NULL CHECK (trabajo_madre IN ('docente', 'salud', 'servicios', 'hogar', 'otro')),
    trabajo_padre VARCHAR(10) NOT NULL CHECK (trabajo_padre IN ('docente', 'salud', 'servicios', 'hogar', 'otro')),
    motivo_eleccion VARCHAR(10) NOT NULL CHECK (motivo_eleccion IN ('cercania', 'reputacion', 'oferta', 'otro')),
    tutor_legal VARCHAR(5) NOT NULL CHECK (tutor_legal IN ('madre', 'padre', 'otro')),
    tiempo_viaje SMALLINT NOT NULL CHECK (tiempo_viaje BETWEEN 1 AND 4),
    tiempo_estudio SMALLINT NOT NULL CHECK (tiempo_estudio BETWEEN 1 AND 4),
    apoyo_escolar BOOLEAN NOT NULL,
    apoyo_familiar BOOLEAN NOT NULL,
    actividades BOOLEAN NOT NULL,
    guarderia BOOLEAN NOT NULL,
    desea_superior BOOLEAN NOT NULL,
    internet BOOLEAN NOT NULL,
    relacion_romantica BOOLEAN NOT NULL,
    relacion_familiar SMALLINT NOT NULL CHECK (relacion_familiar BETWEEN 1 AND 5),
    tiempo_libre SMALLINT NOT NULL CHECK (tiempo_libre BETWEEN 1 AND 5),
    salidas SMALLINT NOT NULL CHECK (salidas BETWEEN 1 AND 5),
    alcohol_semana SMALLINT NOT NULL CHECK (alcohol_semana BETWEEN 1 AND 5),
    alcohol_finde SMALLINT NOT NULL CHECK (alcohol_finde BETWEEN 1 AND 5),
    salud SMALLINT NOT NULL CHECK (salud BETWEEN 1 AND 5)
);

-- Matrícula: resuelve N:M -estudianteasignatura; atributos propios de la asignatura
CREATE TABLE matricula (

```

```

estudiante_id      INTEGER      NOT NULL REFERENCES estudiante (estudiante_id) ON DELETE CASCADE,
asignatura_id      SMALLINT     NOT NULL REFERENCES asignatura (asignatura_id),
reprobaciones_previas SMALLINT  NOT NULL CHECK (reprobaciones_previas BETWEEN 0 AND 3), -- 3 = "3 o más"
" (R-07)
clases_pagadas     BOOLEAN      NOT NULL,
faltas             SMALLINT     NOT NULL CHECK (faltas BETWEEN 0 AND 93),
faltas_confiable   BOOLEAN      NOT NULL, -- anotación de la regla R-09
archivo_origen     VARCHAR(20) NOT NULL, -- linaje: archivo UCI
fila_origen        INTEGER      NOT NULL CHECK (fila_origen >= 2), -- linaje: línea del CSV
PRIMARY KEY (estudiante_id, asignatura_id),
UNIQUE (archivo_origen, fila_origen)
);

-- Calificación: una fila por matrícula y período (1FN de G1, G2, G3) -----
CREATE TABLE calificacion (
  estudiante_id INTEGER NOT NULL,
  asignatura_id SMALLINT NOT NULL,
  periodo_id    SMALLINT NOT NULL REFERENCES periodo (periodo_id),
  nota          SMALLINT NOT NULL CHECK (nota BETWEEN 0 AND 20), -- valor original UCI
  no_evaluado   BOOLEAN NOT NULL, -- anotación de la regla R-08
  PRIMARY KEY (estudiante_id, asignatura_id, periodo_id),
  FOREIGN KEY (estudiante_id, asignatura_id)
    REFERENCES matricula (estudiante_id, asignatura_id) ON DELETE CASCADE,
  CHECK (NOT no_evaluado OR nota = 0)
);

-- Índices justificados -----
-- Las PK ya indexan (estudiante_id, ...). Se añaden índices para los JOIN y
-- filtros de las consultas analíticas (P1: agregación por asignatura y período;
-- tasas por escuela).
CREATE INDEX ix_estudiante_escuela ON estudiante (escuela_id);
CREATE INDEX ix_matricula_asignatura ON matricula (asignatura_id);
CREATE INDEX ix_calificacion_asig_per ON calificacion (asignatura_id, periodo_id);
CREATE INDEX ix_calificacion_periodo ON calificacion (periodo_id) INCLUDE (nota, no_evaluado);

COMMENT ON TABLE calificacion IS 'Notas G1-G3 despivotadas (R-14). nota=0 con no_evaluado=true se excluye de
medias (R-08).';
COMMENT ON COLUMN matricula.reprobaciones_previas IS 'failures UCI; el valor 3 representa 3 o más (R-07).';

```

#### Listado 6: sql/02\_vistas\_seguridad.sql.

```

-- =====
-- 02_vistas_seguridad.sql - Vista de integración y rol de solo lectura
-- =====
SET search_path TO academico;

-- Vista ancha: una fila por matrícula (unidad de análisis del dataset final).
-- Pivota las tres calificaciones y uno atributos de estudiante y escuela.
CREATE OR REPLACE VIEW v_matricula_ancha AS
SELECT
  m.estudiante_id,
  a.codigo AS asignatura,
  e.codigo AS escuela,
  s.sexo, s.edad, s.zona, s.tamano_familia, s.estado_padres,
  s.educ_madre, s.educ_padre, s.trabajo_madre, s.trabajo_padre, s.motivo_eleccion,
  s.tutor_legal, s.tiempo_viaje, s.tiempo_estudio, s.apoyo_escolar, s.apoyo_familiar,
  s.actividades, s.guarderia, s.desea_superior, s.internet, s.relacion_romantica,
  s.relacion_familiar, s.tiempo_libre, s.salidas, s.alcohol_semana, s.alcohol_finde, s.salud,
  m.reprobaciones_previas, m.clases_pagadas, m.faltas, m.faltas_confiable,
  m.archivo_origen, m.fila_origen,
  MAX(c.nota) FILTER (WHERE p.codigo = 'P1') AS nota_p1,
  MAX(c.nota) FILTER (WHERE p.codigo = 'P2') AS nota_p2,
  MAX(c.nota) FILTER (WHERE p.codigo = 'P3') AS nota_p3,
  BOOL_OR(c.no_evaluado) FILTER (WHERE p.codigo = 'P1') AS no_evaluado_p1,
  BOOL_OR(c.no_evaluado) FILTER (WHERE p.codigo = 'P2') AS no_evaluado_p2,
  BOOL_OR(c.no_evaluado) FILTER (WHERE p.codigo = 'P3') AS no_evaluado_p3,
  (SELECT COUNT(*) FROM matricula m2 WHERE m2.estudiante_id = m.estudiante_id) = 2
  AS en_ambas_asignaturas
FROM matricula m
JOIN asignatura a ON a.asignatura_id = m.asignatura_id
JOIN estudiante s ON s.estudiante_id = m.estudiante_id
JOIN escuela e ON e.escuela_id = m.escuela_id
JOIN calificacion c ON c.estudiante_id = m.estudiante_id AND c.asignatura_id = m.asignatura_id

```

```

JOIN periodo      p ON p.periodo_id      = c.periodo_id
GROUP BY m.estudiante_id, a.codigo, e.codigo, s.estudiante_id, m.asignatura_id;

-- Rol de solo lectura para analistas (principio de mínimo privilegio).
DO $$
BEGIN
    IF NOT EXISTS (SELECT 1 FROM pg_roles WHERE rolname = 'analista_lectura') THEN
        CREATE ROLE analista_lectura NOLOGIN;
    END IF;
END $$;
GRANT USAGE ON SCHEMA academico TO analista_lectura;
GRANT SELECT ON ALL TABLES IN SCHEMA academico TO analista_lectura;

```

## B. Diccionario de datos del dataset analítico

Archivo: data/processed/dataset\_analitico.parquet (1044 filas × 58 columnas; tipos explícitos). Origen: *F1 real* = UCI; *F2/F3 SIMULADO*; *Derivada* = calculada en el ETL.

**Tabla 29:** Diccionario de datos del dataset analítico.

| Variable              | Tipo     | Dominio            | Origen   | Descripción                                           |
|-----------------------|----------|--------------------|----------|-------------------------------------------------------|
| estudiante_id         | int32    | 1–674              | F1 real  | Identificador seudonimizado del estudiante            |
| asignatura            | category | MAT, POR           | F1 real  | Asignatura de la matrícula                            |
| escuela               | category | GP, MS             | F1 real  | Centro educativo                                      |
| sexo                  | category | F, M               | F1 real  | Sexo declarado                                        |
| edad                  | int8     | 15–22              | F1 real  | Edad en años                                          |
| zona                  | category | Urbana, Rural      | F1 real  | Tipo de domicilio                                     |
| tamano_familia        | category | ≤3, >3             | F1 real  | Tamaño del hogar                                      |
| estado_padres         | category | Juntos, Separados  | F1 real  | Convivencia de los padres                             |
| educ_madre            | int8     | 0–4                | F1 real  | Nivel educativo de la madre                           |
| educ_padre            | int8     | 0–4                | F1 real  | Nivel educativo del padre                             |
| trabajo_madre         | category | 5 niveles          | F1 real  | Ocupación de la madre                                 |
| trabajo_padre         | category | 5 niveles          | F1 real  | Ocupación del padre                                   |
| motivo_eleccion       | category | 4 niveles          | F1 real  | Motivo de elección del centro                         |
| tutor_legal           | category | madre, padre, otro | F1 real  | Tutor legal                                           |
| tiempo_viaje          | int8     | 1–4                | F1 real  | Tiempo de traslado (ordinal)                          |
| tiempo_estudio        | int8     | 1–4                | F1 real  | Estudio semanal: 1 <2 h, 2 2–5 h, 3 5–10 h, 4 >10 h   |
| apoyo_escolar         | bool     | V/F                | F1 real  | Refuerzo educativo del centro                         |
| apoyo_familiar        | bool     | V/F                | F1 real  | Apoyo educativo familiar                              |
| actividades           | bool     | V/F                | F1 real  | Actividades extracurriculares                         |
| guarderia             | bool     | V/F                | F1 real  | Asistió a educación infantil                          |
| desea_superior        | bool     | V/F                | F1 real  | Aspira a educación superior                           |
| internet              | bool     | V/F                | F1 real  | Internet en el hogar                                  |
| relacion_romantica    | bool     | V/F                | F1 real  | Relación sentimental                                  |
| relacion_familiar     | int8     | 1–5                | F1 real  | Calidad de relaciones familiares                      |
| tiempo_libre          | int8     | 1–5                | F1 real  | Tiempo libre                                          |
| salidas               | int8     | 1–5                | F1 real  | Salidas con amigos                                    |
| alcohol_semana        | int8     | 1–5                | F1 real  | Consumo de alcohol entre semana                       |
| alcohol_finde         | int8     | 1–5                | F1 real  | Consumo de alcohol en fin de semana                   |
| salud                 | int8     | 1–5                | F1 real  | Estado de salud                                       |
| reprobaciones_previas | int8     | 0–3 (3 = 3+)       | F1 real  | Reprobaciones previas en la asignatura                |
| reprobaciones_3mas    | bool     | V/F                | Derivada | Marca de valor truncado (3 o más)                     |
| clases_pagadas        | bool     | V/F                | F1 real  | Clases particulares pagadas en la asignatura          |
| faltas                | int16    | 0–75               | F1 real  | Faltas ANUALES (no disponibles al corte P1; ver L-02) |
| faltas_confiable      | bool     | V/F                | Derivada | Falso si G3 no evaluado y 0 faltas                    |
| faltas_atipicas       | bool     | V/F                | Derivada | Faltas extremas (se conservan)                        |
| nota_p1               | int8     | 0–20               | F1 real  | Nota del 1.er período                                 |

| Variable                    | Tipo     | Dominio                          | Origen              | Descripción                                                  |
|-----------------------------|----------|----------------------------------|---------------------|--------------------------------------------------------------|
| nota_p2                     | int8     | 0–20                             | F1 real             | Nota del 2.º período                                         |
| nota_p3                     | int8     | 0–20                             | F1 real             | Nota final (solo para construir la variable objetivo)        |
| no_evaluado_p1              | bool     | V/F                              | Derivada            | Nota 0 en P1 = no evaluado                                   |
| no_evaluado_p2              | bool     | V/F                              | Derivada            | Nota 0 en P2 = no evaluado                                   |
| no_evaluado_p3              | bool     | V/F                              | Derivada            | Nota 0 en P3 = no evaluado / abandono                        |
| en_ambas_asignaturas        | bool     | V/F                              | Derivada            | El estudiante cursa MAT y POR                                |
| en_riesgo                   | int8     | 0/1                              | Derivada (objetivo) | 1 = reprueba la asignatura (G3 < 10, incluye no evaluados)   |
| rendimiento_sobre_promedio  | boolean  | V/F/NA                           | Derivada            | Solo evaluados en P3; NA si no evaluado                      |
| sim_lms_eventos_p1          | int32    | $\geq 0$                         | F2 SIMULADO         | Eventos LMS en P1                                            |
| sim_lms_minutos_p1          | int32    | $\geq 0$                         | F2 SIMULADO         | Minutos LMS en P1                                            |
| sim_lms_dias_activos_p1     | int16    | $\geq 0$                         | F2 SIMULADO         | Días distintos con actividad en P1                           |
| sim_lms_tareas_revisadas_p1 | int16    | $\geq 0$                         | F2 SIMULADO         | Tareas revisadas en P1                                       |
| sim_lms_eventos_total       | int32    | $\geq 0$                         | F2 SIMULADO         | Eventos LMS del curso (descriptivo; no temprano)             |
| sim_lms_minutos_total       | int32    | $\geq 0$                         | F2 SIMULADO         | Minutos LMS del curso (descriptivo; no temprano)             |
| sim_n_tutorias              | int16    | $\geq 0$                         | F3 SIMULADO         | Tutorías recibidas (P2–P3; posteriores al corte)             |
| sim_n_tutorias_completadas  | int16    | $\geq 0$                         | F3 SIMULADO         | Tutorías completadas                                         |
| sim_n_alertas               | int16    | $\geq 0$                         | F3 SIMULADO         | Alertas registradas (P2)                                     |
| sim_nivel_alerta_max        | int8     | 0–3                              | F3 SIMULADO         | 0 sin alerta, 1 bajo, 2 medio, 3 alto                        |
| sim_alerta_cerrada          | bool     | V/F                              | F3 SIMULADO         | Alguna alerta llegó a 'cerrada'                              |
| particion                   | category | train, test                      | Derivada            | Partición fijada antes del análisis, agrupada por estudiante |
| archivo_origen              | category | student-mat.csv, student-por.csv | Linaje              | Archivo UCI de origen                                        |
| fila_origen                 | int32    | $\geq 2$                         | Linaje              | Línea del CSV de origen                                      |

### C. Linaje de las variables

**Tabla 30:** Linaje: de cada variable a su tabla/colección, campo y regla de transformación.

| Variable        | Origen  | Tabla/colección y campo (transformación) | Regla          |
|-----------------|---------|------------------------------------------|----------------|
| estudiante_id   | F1 real | academico.matricula.estudiante_id        | R-12 identidad |
| asignatura      | F1 real | academico.asignatura.codigo              | R-06           |
| escuela         | F1 real | academico.escuela.codigo (school)        | R-06           |
| sexo            | F1 real | estudiante.sexo (sex)                    | R-06           |
| edad            | F1 real | estudiante.edad (age)                    | —              |
| zona            | F1 real | estudiante.zona (address)                | R-06           |
| tamano_familia  | F1 real | estudiante.tamano_familia (famsize)      | R-06           |
| estado_padres   | F1 real | estudiante.estado_padres (Pstatus)       | R-06           |
| educ_madre      | F1 real | estudiante.educ_madre (Medu)             | —              |
| educ_padre      | F1 real | estudiante.educ_padre (Fedu)             | —              |
| trabajo_madre   | F1 real | estudiante.trabajo_madre (Mjob)          | R-06           |
| trabajo_padre   | F1 real | estudiante.trabajo_padre (Fjob)          | R-06           |
| motivo_eleccion | F1 real | estudiante.motivo_eleccion (reason)      | R-06           |
| tutor_legal     | F1 real | estudiante.tutor_legal (guardian)        | R-06           |
| tiempo_viaje    | F1 real | estudiante.tiempo_viaje (traveltime)     | —              |
| tiempo_estudio  | F1 real | estudiante.tiempo_estudio (studytime)    | —              |
| apoyo_escolar   | F1 real | estudiante.apoyo_escolar (schoolsup)     | R-06           |
| apoyo_familiar  | F1 real | estudiante.apoyo_familiar (famsup)       | R-06           |
| actividades     | F1 real | estudiante.actividades (activities)      | R-06           |
| guarderia       | F1 real | estudiante.guarderia (nursery)           | R-06           |
| desea_superior  | F1 real | estudiante.desea_superior (higher)       | R-06           |
| internet        | F1 real | estudiante.internet (internet)           | R-06           |

| Variable                    | Origen                 | Tabla/colección y campo (transformación)         | Regla                |
|-----------------------------|------------------------|--------------------------------------------------|----------------------|
| relacion_romantica          | F1 real                | estudiante.relacion_romantica (romantic)         | R-06                 |
| relacion_familiar           | F1 real                | estudiante.relacion_familiar (famrel)            | —                    |
| tiempo_libre                | F1 real                | estudiante.tiempo_libre (freetime)               | —                    |
| salidas                     | F1 real                | estudiante.salidas (goout)                       | —                    |
| alcohol_semana              | F1 real                | estudiante.alcohol_semana (Dalc)                 | —                    |
| alcohol_finde               | F1 real                | estudiante.alcohol_finde (Walc)                  | —                    |
| salud                       | F1 real                | estudiante.salud (health)                        | —                    |
| reprobaciones_previas       | F1 real                | matricula.reprobaciones_previas (failures)       | R-07                 |
| reprobaciones_3mas          | Derivada               | reprobaciones_previas = 3                        | R-07                 |
| clases_pagadas              | F1 real                | matricula.clases_pagadas (paid)                  | R-06                 |
| faltas                      | F1 real                | matricula.faltas (absences)                      | —                    |
| faltas_confiable            | Derivada               | matricula.faltas_confiable                       | R-09                 |
| faltas_atipicas             | Derivada               | faltas > Q3 + 3·RIC por asignatura               | R-10                 |
| nota_p1                     | F1 real                | calificacion.nota, periodo P1 (G1)               | R-14                 |
| nota_p2                     | F1 real                | calificacion.nota, periodo P2 (G2)               | R-14                 |
| nota_p3                     | F1 real                | calificacion.nota, periodo P3 (G3)               | R-14                 |
| no_evaluado_p1              | Derivada               | calificacion.no_evaluado, P1                     | R-08                 |
| no_evaluado_p2              | Derivada               | calificacion.no_evaluado, P2                     | R-08                 |
| no_evaluado_p3              | Derivada               | calificacion.no_evaluado, P3                     | R-08                 |
| en_ambas_asignaturas        | Derivada               | COUNT(matricula) = 2                             | R-12                 |
| en_riesgo                   | Derivada<br>(objetivo) | nota_p3 < 10                                     | Def. operativa       |
| rendimiento_sobre_promedio  | Derivada               | nota_p3 > media de la asignatura                 | P2                   |
| sim_lms_eventos_p1          | F2 SIMULADO            | seguimiento_riesgo.interacciones_lms (P1), AG-01 | R-15...R-22,<br>R-26 |
| sim_lms_minutos_p1          | F2 SIMULADO            | interacciones_lms.duracion_min (P1), AG-01       | R-21, R-22,<br>R-26  |
| sim_lms_dias_activos_p1     | F2 SIMULADO            | interacciones_lms.fecha (P1), AG-01              | R-26                 |
| sim_lms_tareas_revisadas_p1 | F2 SIMULADO            | interacciones_lms.revisada (P1), AG-01           | R-26                 |
| sim_lms_eventos_total       | F2 SIMULADO            | interacciones_lms (P1–P3), AG-01                 | R-26                 |
| sim_lms_minutos_total       | F2 SIMULADO            | interacciones_lms (P1–P3), AG-01                 | R-26                 |
| sim_n_tutorias              | F3 SIMULADO            | seguimiento_riesgo.tutorias, AG-02               | R-23, R-26           |
| sim_n_tutorias_completadas  | F3 SIMULADO            | tutorias.resultado = completada, AG-02           | R-23, R-26           |
| sim_n_alertas               | F3 SIMULADO            | alertas_riesgo, AG-03                            | R-24, R-26           |
| sim_nivel_alerta_max        | F3 SIMULADO            | alertas_riesgo.nivel, AG-03                      | R-26                 |
| sim_alerta_cerrada          | F3 SIMULADO            | alertas_riesgo.estado, AG-03                     | R-24, R-26           |
| particion                   | Derivada               | StratifiedGroupKfold(5, seed 42), 1.er pliegue   | L-04                 |
| archivo_origen              | Linaje                 | matricula.archivo_origen                         | —                    |
| fila_origen                 | Linaje                 | matricula.fila_origen                            | —                    |

## D. Correspondencia con el dataset esperado del avance

**Tabla 31:** Variables del dataset esperado en el avance y su tratamiento final.

| Variable del avance           | Variable final                             | Decisión                                                               |
|-------------------------------|--------------------------------------------|------------------------------------------------------------------------|
| estudiante_id                 | estudiante_id                              | Se mantiene; ahora con regla de identidad documentada (R-12).          |
| periodo ("2026-1")            | columnas nota_p1/p2/p3 + corte             | Etiqueta errónea; los periodos son P1–P3 de 2005–06 (config.PERIODOS). |
| escuela, zona, tiempo_estudio | escuela, zona, tiempo_estudio              | Sin cambios.                                                           |
| promedio_general              | nota_p1 (y nota_p2 en el escenario B)      | Eliminado: incluía G3 (fuga de información).                           |
| faltas_totales                | faltas                                     | Por matrícula; anual (no se usa en el modelo temprano, L-02).          |
| reprobaciones_totales         | reprobaciones_previas                      | Por matrícula (failures depende de la asignatura).                     |
| n_interacciones_lms           | sim_lms_eventos_p1 / sim_lms_eventos_total | Prefijo sim_: variable simulada.                                       |
| minutos_lms                   | sim_lms_minutos_p1 / sim_lms_minutos_total | Prefijo sim_: variable simulada.                                       |
| n_tutorias                    | sim_n_tutorias                             | Posterior al corte P1: solo descriptiva.                               |
| en_riesgo                     | en_riesgo                                  | Definida: $G3 < 10$ (incluye no evaluados).                            |

*Fuente:* data/processed/mapeo\_avance\_final.csv.

## E. Posibles falsos negativos de la regla de identidad

**Tabla 32:** Pares sin emparejar que coinciden en 26 de 27 atributos (regla R-12b; no fusionados).

| Línea MAT | Línea POR | Atributo distinto | Valor MAT | Valor POR |
|-----------|-----------|-------------------|-----------|-----------|
| 163       | 177       | age               | 15        | 17        |
| 164       | 178       | age               | 16        | 15        |
| 165       | 179       | age               | 17        | 16        |
| 167       | 181       | age               | 16        | 17        |
| 362       | 620       | Fedu              | 4         | 2         |

*Fuente:* data/staging/identidad\_posibles\_falsos\_negativos.csv. Línea = número de línea en el CSV original.

## F. Salidas adicionales

**Listado 7:** Documento de `alertas_riesgoSIM` con historial y notas normalizadas (`results/mongo_documentos_ejemplo.json`).

```
{
  "alerta_id": "AL-00002",
  "estudiante_id": 1,
  "asignatura": "POR",
  "periodo": "P2",
  "nivel": "alto",
  "estado": "cerrada",
  "creada_en": "2006-01-16T11:00:00",
  "actualizado_en": "2006-04-06T11:00:00",
  "historial_estados": [
    {
      "estado": "abierta",
      "fecha": "2006-01-16T11:00:00"
    },
    {
      "estado": "en_seguimiento",
      "fecha": "2006-01-27T11:00:00"
    },
    {

```

```

"estado": "cerrada",
"fecha": "2006-04-06T11:00:00"
},
],
"notas": [
{
"nota_id": "AL-00002-N2",
"fecha": "2006-01-27T12:00:00",
"autor": "ORI-03",
"texto": "Registro de asistencia irregular durante el período; se solicita justificación.",
"texto_normalizado": "registro de asistencia irregular durante el periodo se solicita justificacion",
"categoria": "asistencia"
},
{
"nota_id": "AL-00002-N1",
"fecha": "2006-04-02T12:00:00",
"autor": "ORI-02",
"texto": "RETRASOS Y AUSENCIAS FRECUENTES EN LA JORNADA DE LENGUA PORTUGUESA.",
"texto_normalizado": "retrasos y ausencias frecuentes en la jornada de lengua portuguesa",
"categoria": "asistencia"
}
],
"es_simulado": true,
"fuelle": "generate_synthetic v1.0 (seed=42)"
}

```

**Tabla 33:** Términos más frecuentes en las notas normalizadas<sup>SIM</sup>.

| Término       | Frecuencia |
|---------------|------------|
| periodo       | 186        |
| estudiante    | 161        |
| lengua        | 119        |
| portuguesa    | 119        |
| matematicas   | 99         |
| representante | 78         |
| presenta      | 74         |
| bajo          | 74         |
| rendimiento   | 74         |
| recomienda    | 74         |

*Fuente:* results/texto\_terminos.csv.